

Membaca Skala, Bukan Menebak Kelas

Prediksi kepuasan hidup dari 176 variabel survei, dirancang untuk satu metrik.

DISTRIBUSI TARGET · 95.609 BARIS LATIH



0,48425

QWK out-of-fold

6

Keluarga algoritma

176

Fitur mentah

42

Seed, dikunci

0

Baris data eksternal

Tebakan teraman di kompetisi ini bernilai tepat nol.

50,402%

Akurasi bila menebak kelas mayoritas untuk semua orang

0,000000

QWK untuk tebakan yang sama persis

Metrik lomba ini tidak memberi imbalan pada tebakan aman. Seluruh strategi kami turun dari satu fakta itu.

Enam pertanyaan, dijawab berurutan.

Tiap babak menutup satu pertanyaan sebelum babak berikutnya dibuka.

I

Apa yang diprediksi, dan metrik apa yang menilainya?

Latar, data, QWK

II

Apa kata data sebelum satu model pun dilatih?

Sepuluh temuan EDA

III

Bagaimana temuan itu menjadi keputusan pemodelan?

Preprocessing sampai stacking

IV

Bagaimana kami menahan diri dari menempel pada derau?

Studi ambang dan uji split-half

V

Seberapa baik hasilnya, dan di mana ia gagal?

Diagnostik dan analisis plafon

VI

Bisakah diulang, dan apa gunanya di luar lomba?

Reproduksi dan produk

BABAK I

Latar, data, dan metrik.

Apa yang diprediksi, dari data seperti apa, dan dengan penggaris apa hasilnya diukur.

95.609 baris latih, 176 fitur

23.902 baris uji, 23.666 id unik

Empat tahun survei, 2021 sampai 2024

Quadratic Weighted Kappa

Kepuasan hidup adalah indikator kesejahteraan, bukan sekadar perasaan.

Tiga temuan riset yang membingkai masalah ini sebelum satu baris data dibuka.

OECD, 2013

Standar pengukuran

Guidelines on Measuring Subjective Well-being menjadikan evaluasi hidup ukuran inti kesejahteraan nasional, berdampingan dengan PDB.

Artinya: target ini dipakai pembuat kebijakan, bukan hanya peneliti.

WHO, 2023

± 280 juta orang

hidup dengan depresi di seluruh dunia, sekitar 5% orang dewasa. Rasa tidak puas yang berkepanjangan adalah salah satu sinyal awalnya.

Artinya: menemukan kelas 3 dan 4 lebih dini punya nilai kesehatan masyarakat.

KAHNEMAN & DEATON, 2010

Pendapatan dan evaluasi hidup

Evaluasi hidup naik mengikuti logaritma pendapatan, sementara kesejahteraan emosional mendatar di atas ambang tertentu.

Artinya: `income_to_poverty_ratio` wajar muncul di jajaran fitur teratas.

Rumusan masalah: dari 176 variabel survei kesehatan, seberapa tepat kita bisa menempatkan seseorang pada skala kepuasan hidup, dan siapa yang paling perlu ditindaklanjuti?

Satu pertanyaan survei, empat jawaban berurutan.

Seberapa puas seseorang dengan hidupnya, diprediksi dari 176 variabel survei kesehatan.

Yang diprediksi

	Sangat puas	42.968 baris
	Puas	48.189 baris
	Tidak puas	3.559 baris
	Sangat tidak puas	893 baris

Skalanya berurutan, jadi jarak antar jawaban punya arti.

Spesifikasi berkas

train_final.csv	95.609 × 179
test_final.csv	23.902 × 178
data_dictionary.csv	187 × 3
Fitur numerik dipakai	176
Tahun survei tercakup	2021 sampai 2024
id unik di berkas uji	23.666 dari 23.902
Baris duplikat penuh	1.892 latih, 472 uji

QWK menghitung jarak, bukan salah atau benar.

Bobot penaltinya kuadratik terhadap selisih kelas, jadi seberapa jauh melesetnya yang dihukum.

$$\kappa = 1 - \sum w_{ij} O_{ij} / \sum w_{ij} E_{ij}$$

$$w_{ij} = (i - j)^2 / 9$$

O adalah matriks konfusi teramati, E matriks ekspektasi di bawah independensi. Empat kelas, jadi penyebut bobotnya 9.

Kami mengimplementasikannya ulang secara tervektorisasi, 47 kali lebih cepat, dan memverifikasinya terhadap scikit-learn sampai selisih $4,44 \times 10^{-16}$.


		prediksi			
		1	2	3	4
aktual	1	0	1	4	9
	2	1	0	1	4
	3	4	1	0	1
	4	9	4	1	0

Menebak kelas 4 sebagai 1 dihukum **9 kali** lebih berat daripada menebak 2 sebagai 1.

Maka targetnya skala, bukan empat kotak terpisah.

Untuk galat kuadratik, keputusan optimal adalah nilai harapan, bukan modus.

$$E[y] = \sum p_k \cdot k$$



Tiga bilangan itulah keputusan akhir pipeline ini. Seluruhnya diestimasi dari prediksi out-of-fold data latih, tidak pernah dari data uji.

Kenapa masalah ini sulit: empat akar, empat jawaban.

Setiap akar menentukan satu babak berikutnya. Deck ini disusun mengikuti pohon ini.



BABAK II

Apa kata data, sebelum satu model pun dilatih.

Sepuluh temuan, masing-masing dengan konsekuensi desain yang disebutkan eksplisit.

Distribusi target dan pola kosong

Kode non-respons 7, 8, dan 9

Bentuk sinyal dan sebarannya

Dua jebakan yang kami tolak

Dua kelas menguasai 95,3% data. Keduanya bukan penentu skor.

Kelas 3 dan 4 hanya 4.452 baris, tetapi memikul hampir seluruh bobot penalti.

1 · Sangat puas



44,94% · 42.968 baris

2 · Puas




50,40% · 48.189 baris

3 · Tidak puas



3,72% · 3.559 baris

4 · Sangat tidak puas



0,93% · 893 baris

9 : 1

Penalti satu galat kelas 4 dibanding satu galat kelas tetangga

4,7%

Porsi responden di dua kelas terbawah

Implikasi desain. Model harus berani menebak kelas langka. Karena itu kami mengoptimalkan ambang batas, bukan memakai argmax.

Setiap kolom punya nilai kosong. Tidak satu pun kami imputasi.

Pola kosong di data latih dan data uji hampir identik, jadi tidak ada pergeseran yang perlu ditambah.

14,41%

Rata-rata sel kosong

0 dari 176

Kolom tanpa kosong sama sekali

25,4

Rata-rata nilai hilang per baris

Kolom dengan kosong tertinggi	latih	uji	selisih
flu_vaccine_year	53,85%	54,28%	0,43
flu_vaccine_month	53,43%	54,08%	0,65
ever_married	52,11%	52,09%	0,02
gestational_diabetes_ever	50,02%	49,21%	0,81
works_full_time	48,59%	48,57%	0,02
hours_worked_per_week	48,51%	48,41%	0,10

Kenapa tanpa imputasi

LightGBM, XGBoost, dan CatBoost mempelajari sendiri arah cabang untuk nilai hilang. Mengganti dengan median justru menciptakan massa buatan di satu titik.

Keputusan ini diuji lewat ablasi, bukan diasumsikan.

Kode 7, 8, dan 9 bukan sampah. Kami biarkan apa adanya.

Menolak menjawab, tidak terjawab, dan tidak tahu ternyata punya rata-rata target sendiri.


Sebaran kode khusus

84 kolom

Kolom biner Ya/Tidak yang memuat kode 7, 8, atau 9

insurance_has_deductible_plan1	8,12%
insurance_covers_vision_plan1	7,11%
insurance_covers_dental_plan1	6,13%
has_investment_income	5,80%

Rata-rata target menurut general_health_status



Monoton naik di seluruh lima tingkat. Sinyalnya nyata.

Implikasi desain. Model pohon dapat mengisolasi kode ini sebagai cabang tersendiri. Mengubahnya menjadi NaN diuji di ablasi dan tidak memberi perbaikan.

Prediktor terkuatnya monoton. Itu yang membenarkan perlakuan ordinal.

Rentang rata-rata target antar tingkat, untuk tujuh variabel teratas.




Kesehatan umum memburuk, depresi makin sering, ketahanan pangan makin rapuh. Ketiganya menaikkan rata-rata target secara konsisten, tanpa pembalikan arah.

Implikasi desain. Struktur monoton pada fitur adalah alasan kami menambahkan regresi Huber dan dekomposisi biner kumulatif di samping klasifikasi biasa. Ketiganya membaca skala, bukan kategori.

Tidak ada fitur dominan. Sinyalnya tersebar tipis.

Prediktor tunggal terkuat hanya mencapai korelasi 0,361 terhadap target.



Pasangan paling redundan	korelasi
data_year · survey_year	1,000
children_in_family · children_in_household	0,998
ever_used_ecigarette · ecigarette_status	0,997
health_insurance_type · private_health_insurance	0,982
cancer_ever · cancer_types_count	0,981
income_to_poverty_ratio · income_poverty_category	0,961

Implikasi desain. Redundansi terpusat pada segelintir pasangan yang memang kembar. Selebihnya tidak ada fitur yang bisa dibuang tanpa kehilangan sedikit sinyal, jadi seleksi fitur agresif kami tolak dan seluruh 176 fitur dipertahankan.

Empat tahun survei, satu perilaku yang sama.

Data melintasi pandemi dan pemulihannya, jadi pergeseran temporal wajib diperiksa lebih dulu.

Tahun survei	jumlah	rata-rata target	% kelas 1	% kelas 3+4
2021	21.464	1,5914	47,27%	5,25%
2022	20.417	1,6105	44,45%	4,53%
2023	21.849	1,6153	43,78%	4,49%
2024	24.230	1,6070	44,45%	4,35%

0,0239


Total pergerakan rata-rata target sepanjang empat tahun

Proporsi tahun di data latih dan data uji juga nyaris identik.

Implikasi desain. Tidak ada pergeseran distribusi antar tahun, sehingga satu model untuk seluruh periode sudah tepat. Fitur indikator tahun dan model terpisah per tahun keduanya kami uji lalu tolak.

Yang tidak direkam survei ini justru penentu terbesarnya.

Kekuatan sinyal per domain variabel, diukur dengan korelasi Spearman terhadap target.



Tidak ada di berkas mana pun

- Kepribadian
- Kualitas hubungan sosial
- Rasa bermakna hidup
- Adaptasi hedonik

Literatur kesejahteraan subjektif menempatkan keempatnya di barisan depan. Survei kesehatan tidak merekam satu pun.

Implikasi desain. Ini landasan substantif analisis plafon di Babak V. Sebagian besar variasi target berada di luar jangkauan instrumen pengukuran, bukan di luar jangkauan algoritma.

Dua jebakan kebocoran. Kami ukur dulu, baru buang.

61,3% baris uji punya anggota rumah tangga yang labelnya sudah ada di data latih.

JEBAKAN 1 · TARGET ENCODING RUMAH TANGGA

Anggota rumah tangga lain menjawab	P(y = 1)
1 Sangat puas	0,4654
2 Puas	0,4347
3 Tidak puas	0,4280
4 Sangat tidak puas	0,4294

44,9% → 46,5% · lift +1,6 poin persentase

Itu seluruh lift yang ditawarkan struktur rumah tangga. Kepuasan hidup ternyata jauh lebih individual daripada dugaan awal.

Keduanya dibuang berdasarkan besaran sinyalnya, sebelum melihat skor apa pun.

JEBAKAN 2 · KOLOM id SEBAGAI FITUR

Spearman(id, target)	0,00595
Rata-rata target per 20 bin id	1,5925 sampai 1,6251
Rata-rata target marginal	1,6065

Praktis datar. Tidak ada kebocoran urutan, jadi id dikeluarkan dari fitur.

Temuan sampingan yang menyelamatkan submission. id di berkas uji tidak unik, 23.666 id untuk 23.902 baris, jadi berkas submission harus berisi 23.666 baris.

Tiap keputusan desain terlacak ke satu temuan EDA.

Tidak ada keputusan yang diambil karena kebiasaan.

TEMUAN EDA	ARTINYA	KEPUTUSAN DESAIN
Target timpang 44,9 / 50,4 / 3,7 / 0,9	→ Baseline QWK nol meski akurasi 50,4%	→ Optimasi ambang, bukan argmax
QWK berbobot kuadratik	→ Galat berjarak jauh dihukum 9 kali	→ Perlakuan ordinal lewat nilai harapan
Kosong 14,4% sel, pola latih sama dengan uji	→ Tidak ada pergeseran distribusi	→ Tanpa imputasi, pohon menangani NaN
Kode 7/8/9 punya rata-rata target berbeda	→ Non-respons membawa sinyal	→ Kode dipertahankan apa adanya
Prediktor kuat bersifat monoton	→ Struktur ordinal nyata pada fitur	→ Regresi Huber dan dekomposisi kumulatif
Lift antar anggota rumah tangga +1,6pp	→ Kepuasan hidup sangat individual	→ household_id dibuang
Spearman(id, target) = 0,006	→ Tidak ada kebocoran urutan	→ id dibuang dari fitur
Median korelasi antar fitur 0,037	→ Seleksi fitur agresif merugikan	→ Seluruh 176 fitur dipertahankan
Rata-rata target bergerak 0,0239 antar tahun	→ Tidak ada pergeseran temporal	→ Satu model untuk seluruh periode
Domain psikososial tidak terekam	→ Sebagian besar variasi tak teramati	→ Landasan analisis plafon

BABAK III

Dari temuan menjadi pipeline.

Sepuluh keputusan desain dijalankan, lalu masing-masing diuji ulang lewat ablasi.

Preprocessing tanpa imputasi

Fitur komposit dibuat lalu dibuang

Enam keluarga algoritma

Stacking dan tiga ambang batas

Tujuh keputusan preprocessing, tujuh alasan yang bisa diperiksa.

Setiap baris punya bukti empiris di bagian ablasi. Tidak ada yang diambil sebagai kebiasaan.

Keputusan	Pilihan kami	Dasarnya
Nilai kosong	Dibiarkan sebagai NaN	Pohon belajar arah cabang sendiri
Kode 7 / 8 / 9	Dibiarkan apa adanya	Non-respons membawa sinyal
Penskalaan model pohon	Tidak dilakukan	Invarian terhadap transformasi monoton
Penskalaan untuk MLP	QuantileTransformer + median	Jaringan saraf butuh input ternormalisasi
household_id	Dibuang	Lift antar anggota hanya +1,6pp
id	Dibuang	Spearman terhadap target 0,006
Encoding kategorikal	Tidak diperlukan	Seluruh kolom sudah berupa kode numerik

Hasilnya: matriks fitur 95.609×176 untuk model pohon, dan versi ternormalisasi berukuran sama untuk MLP.

Kami buat 13 fitur komposit, lalu membuangnya semua.


Dibuat berdasarkan pengelompokan domain di data dictionary, lalu diuji dengan CV 3-fold yang identik.

YANG KAMI BANGUN

n_disease	n_difficulty
n_cost_barrier	n_mental
n_income_src	n_missing
sev_anxiety	sev_depression
sev_mental	sev_food
health_x_mental	poverty_x_health
bmi	

Indeks beban penyakit, keterbatasan fungsional, hambatan biaya, keparahan mental, ketahanan pangan.

YANG DIKATAKAN ABLASI



Garis tegak adalah konfigurasi A. Kedua selisih lebih kecil dari 0,0012 QWK.

Skema ablasi

CV 3-fold identik

Waktu ablasi

297 detik

Keputusan: fitur mentah saja. Selisihnya di level derau fold. Pohon dengan 176 fitur sudah merekonstruksi sendiri interaksi semacam jumlah penyakit lewat kombinasi percabangan.

Kami menulis ulang metrik lombanya sendiri, lalu membuktikannya setara.

Pencarian ambang butuh puluhan ribu evaluasi QWK. Versi scikit-learn terlalu lambat untuk itu.

Verifikasi kesetaraan

Selisih maksimum vs sklearn	$4,44 \times 10^{-16}$
Jumlah uji acak	200
qwk_fast	43 μ s per panggilan
cohen_kappa_score	2.029 μ s per panggilan

47 ×

Lebih cepat, dan itu yang membuat studi ambang batas 25 menit menjadi mungkin

Dari probabilitas ke label, tiga langkah

1

Rata-ratakan probabilitas

Lima model pohon, empat kelas, satu matriks p



2

Hitung nilai harapan

$E[y] = \sum p_k \cdot k$, satu bilangan kontinu per responden



3

Potong dengan tiga ambang


Label akhir 1, 2, 3, atau 4

Satu pembagian fold, dipakai keenam model tanpa kecuali.

Itu syarat agar prediksi out-of-fold keenamnya bisa ditumpuk menjadi matriks fitur meta-learner.

Skema	
Metode	StratifiedKFold
Jumlah fold	5, dengan pengacakan
random_state pembagian	42
Seed model per fold	0, 1, 2, 3, 4
Ukuran latih per fold	76.487 atau 76.488
Ukuran validasi per fold	19.121 atau 19.122

Lima fold, stratifikasi menjaga proporsi kelas langka



 blok validasi, tempat prediksi out-of-fold diambil

Kenapa ini penting. Ambang batas dan pemilihan model seluruhnya ditentukan dari prediksi out-of-fold data latih. Data uji tidak pernah terlibat dalam satu pun keputusan, sehingga estimasi OOF tetap menjadi penduga tak bias untuk kinerja papan peringkat, sekaligus memenuhi larangan probing pada pasal B.1.c.

Enam keluarga algoritma, dipilih agar saling berbeda.

Tujuannya menutup sudut pandang yang berbeda terhadap masalah ordinal, bukan menumpuk model.

	Keluarga	Sudut pandang	Konfigurasi inti
lgb	Boosting leaf-wise	Klasifikasi 4 kelas	1.500 pohon, lr 0,028, 127 daun
cat	Ordered boosting	Penanganan bias berbeda	1.800 iterasi, lr 0,05, depth 8
xgb	Boosting level-wise	Regularisasi berbeda	1.200 pohon, lr 0,04, depth 8
reg	Regresi Huber	Target sebagai skala kontinu	1.500 pohon, lr 0,03, tahan pencilan
ord	Dekomposisi kumulatif	Tiga model $P(y > k)$	3×1.200 pohon, $k = 1, 2, 3$
mlp	Jaringan saraf	Batas keputusan mulus	Fitur ternormalisasi kuantil

reg dan ord ada di daftar ini karena temuan monotonisitas di Babak II, bukan karena melengkapi koleksi.

Total waktu pelatihan **52,2 menit** untuk keenam model $\times$ lima fold pada CPU 12 core.

Setiap komponen berdiri di atas metode yang sudah teruji.

Tidak ada komponen buatan sendiri yang belum pernah divalidasi di literatur.

Komponen pipeline	Landasan	Dipakai untuk
Quadratic Weighted Kappa	Cohen (1968), weighted kappa	Metrik evaluasi dan objektif ambang
Dekomposisi biner kumulatif	Frank & Hall (2001)	Model ord: tiga model $P(y > k)$
Gradient boosting	Friedman (2001)	Dasar lgb, xgb, cat, reg
LightGBM leaf-wise	Ke dkk. (2017)	Model lgb, reg, ord
XGBoost level-wise	Chen & Guestrin (2016)	Model xgb
CatBoost ordered boosting	Prokhorenkova dkk. (2018)	Model cat, mengurangi prediction shift
Huber loss	Huber (1964)	Regresi yang tahan pencilan
Stacked generalization	Wolpert (1992)	Penggabungan model dasar
Bootstrap	Efron (1979)	Reduksi variansi ambang dan derau papan skor
Keputusan optimal galat kuadratik	Teori keputusan Bayes	Nilai harapan, bukan modus

Enam keluarga algoritma mendarat di titik yang sama.

Bias induktifnya sangat berbeda. Kelima model pohon hanya terpaut 0,00267 QWK.



0,00267

Rentang kelima model pohon

0,974

Korelasi rata-rata prediksi antar model pohon

Ketika kelas fungsi yang berbeda mendarat di titik yang sama, dindingnya milik data.

Sumbu dipotong pada 0 agar panjang batang sebanding. Selisih sesungguhnya jauh lebih sempit daripada yang terlihat.

Kombinasinya ditetapkan di muka, bukan dipilih dari papan skor.

Empat kandidat dievaluasi pada matriks probabilitas OOF berukuran 95.609×24 .

Kandidat kombinasi	QWK OOF	t_1	t_2	t_3
rata-rata lima model pohon	0,48517	1,5543	2,0027	2,3936
regresi logistik sebagai meta	0,48398	1,5601	2,0033	2,5525
rata-rata keenam model	0,48361	1,5524	2,0067	2,4103
LightGBM sebagai meta	0,48307	1,5591	2,0525	2,5309

+0,00403

Sumbangan kombinasi di atas model dasar terbaik

Dua alasan yang ditetapkan di muka

Rata-rata sederhana tidak punya parameter yang bisa menempel pada derau, dan model dasar sudah berkorelasi 0,974.

MLP dikeluarkan karena QWK tunggalnya jelas di bawah kelima model pohon, dan rata-rata tanpa bobot memberi porsi sama ke tiap anggota.

Keduanya bisa diperiksa tanpa menyentuh data uji. Setelah dihitung, kombinasi yang kami tetapkan itu juga yang tertinggi pada OOF, jadi disiplin a priori di sini tidak menuntut pengorbanan skor sama sekali.

Tiga bilangan, dicari dua tahap.

Pencarian grid berbasis kuantil lebih dulu, lalu dihaluskan dengan pencarian koordinat.

Prosedur pencarian

Grid kuantil, $45 \times 32 \times 26$ titik	0,48446
Setelah pencarian koordinat	0,48517
Waktu penghalusan	48 detik

t_1

1,5543

batas kelas 1 | 2

t_2

2,0027

batas kelas 2 | 3

t_3

2,3936

batas kelas 3 | 4

Seluruhnya dari prediksi out-of-fold data latih. Data uji tidak pernah menyentuh angka ini.

Kenapa dua tahap

Grid kuantil menjamin cakupan seluruh rentang tanpa terjebak di satu wilayah, sementara pencarian koordinat menajamkan hasilnya di sekitar optimum. Kenaikan dari 0,48446 ke 0,48517 adalah selisih antara kedua tahap itu. Slide berikutnya menunjukkan apa yang sebenarnya dibeli oleh ketiga bilangan ini.

Akurasinya turun. Skornya naik. Itu jawaban yang benar.


Beralih dari argmax ke nilai harapan dengan ambang batas, pada model yang sama persis.

Strategi keputusan	QWK	akurasi	% prediksi kelas 3+4
argmax probabilitas	0,42460	0,66943	0,96%
nilai harapan + ambang batas	0,48517	0,63258	8,58%

+0,06057

Kenaikan QWK dari satu perubahan aturan keputusan

PORSI LABEL KELAS 3 DAN 4 YANG DIHASILKAN



Oranye kelas 3, merah kelas 4. argmax memprediksi kelas 4 hanya 0,02% dari waktu.

argmax nyaris tidak pernah memprediksi kelas 3 dan 4, karena probabilitas posteriornya jarang menjadi yang tertinggi. Akibatnya setiap responden yang sangat tidak puas menjadi galat berjarak jauh dengan penalti 9 kali.

Ambang batas memaksa model mengambil risiko terkalibrasi.

89,9% perbaikan kami datang dari aturan keputusan.

Enam baseline dijalankan penuh, bukan diestimasi, agar tiap komponen bisa dipisahkan.



+0,06269 baris 4 ke 5, hanya aturannya yang berubah

+0,00708 lima model lagi, stacking, dan studi ambang

BABAK IV

Bagaimana kami menahan diri.

Tiga bilangan ambang ditentukan dari data yang sama yang dipakai menilainya. Di situlah godaan terbesarnya.

Lima strategi estimasi diuji

Uji split-half sebagai wasit

Satu ide kami sendiri terbukti overfit

Rentang 20 konfigurasi hanya 0,003

Lima cara mengestimasi tiga bilangan yang sama.

Seluruhnya hanya memakai prediksi out-of-fold data latih. Tidak satu pun menyentuh data uji.

Strategi	Gagasan	QWK OOF	t ₁	t ₂	t ₃
a. titik tunggal	argmax QWK pada OOF	0,48517	1,5543	2,0027	2,3936
b. rata-rata bootstrap	25 resample, lalu dirata-rata	0,48425	1,5513	2,0051	2,3942
c. rata-rata subsample	Subsampil 80% tanpa pengembalian	0,48419	1,5433	2,0007	2,4094
d. cocok distribusi	Kuantil sesuai proporsi kelas	0,47413	1,5278	2,1263	2,5340
e. objektif dihaluskan	Maksimalkan QWK rata-rata atas jitter	0,48435	1,5450	1,9934	2,3936

Strategi b dan c adalah teknik reduksi variansi standar. Bila permukaan QWK di sekitar optimum landai dan bergerigi, merata-ratakan lintas resample menempatkan ambang di pusat dataran tinggi, bukan pada satu puncak derau. Waktu studi ini 23,7 menit.

Kriteria yang benar bukan skor tertinggi, melainkan yang paling stabil.

Pasang ambang pada separuh OOF, nilai pada separuh yang belum pernah dilihat.

Strategi	in-sample	held-out	selisih
b. rata-rata bootstrap	0,48625	0,48106	0,00519
c. rata-rata subsample	0,48654	0,48100	0,00554
a. titik tunggal	0,48688	0,48083	0,00606
d. cocok distribusi	0,47650	0,47206	0,00444

Strategi a memenangkan kolom in-sample dan kalah di kolom held-out. Selisih terbesar itulah ukuran seberapa jauh ia menempel pada derau.

SEBARAN AMBANG ANTAR 25 BOOTSTRAP



Simpangan baku ambang antar resample bootstrap.

Keputusan: rata-rata bootstrap. Kami menetapkan ini di muka dengan alasan statistik, bukan hasil perbandingan skor. t₃ hampir empat kali lebih goyah daripada t₁, sejalan dengan kenyataan bahwa kelas 4 hanya punya 893 sampel latih. Di situlah reduksi variansi paling dibutuhkan.

Kami membangun alat untuk membunuh ide kami sendiri.

Ambang batas terpisah per segmen terdengar benar, dan skornya memang naik.

YANG TERLIHAT


QWK naik

Makin banyak segmen, makin tinggi skornya pada himpunan tempat ambang dipasang. Kami menguji segmentasi menurut tahun survei, status kesehatan, usia, dan silangannya.

YANG SEBENARNYA TERJADI

Held-out turun

Uji split-half menunjukkan setiap parameter ambang tambahan menaikkan skor in-sample dan menurunkan skor held-out, secara monoton.



Ditolak. Tanpa uji split-half, konfigurasi ini akan terlihat sebagai perbaikan terbesar kedua dalam proyek, dan akan merugikan kami di data uji.

Di antara varian yang sama-sama masuk akal, tidak ada kriteria yang memandu.

Dua puluh konfigurasi, lima cara menggabungkan model dikali empat strategi ambang yang wajar.

Kriteria seleksi berbasis data latih	Korelasi dengan kinerja pada data uji
QWK out-of-fold	$\approx 0,08$
QWK held-out dari uji split-half	$\approx 0,16$

Angka ini sempat terlihat jauh lebih informatif ketika kelima strategi diperhitungkan. Ternyata seluruhnya digerakkan satu strategi yang memang jelas buruk, yaitu pencocokan distribusi. Setelah strategi itu dikeluarkan, kedua kriteria praktis tidak berkorelasi.

0,003

Rentang QWK di antara kedua puluh konfigurasi itu

25

Konfigurasi dievaluasi selama pengembangan

Mengejar skor tertinggi pada rentang ini bukan optimasi. Itu memilih derau.

BABAK V

Hasilnya, dan di mana ia gagal.

Angka akhir, peta penalti, kegagalan per subkelompok, lalu pertanyaan apakah angka ini bisa dinaikkan sama sekali.

QWK out-of-fold 0,48425

Satu sel menyumbang 35,8% penalti

Kurva belajar lima titik

Derau papan skor 0,7 sigma

QWK out-of-fold 0,48425, dari lima fold penuh.

Matriks konfusi out-of-fold atas seluruh 95.609 baris latih.

		prediksi			
		1	2	3	4
aktual	1	30.414	11.918	576	60
	2	14.757	28.477	4.389	566
	3	157	1.412	1.369	621
	4	140	226	262	265

0,48425

QWK out-of-fold

0,63305

Akurasi out-of-fold

0,00000


Warna mengikuti jumlah baris. Diagonalnya prediksi yang tepat.

Kelas 4 tertangkap 265 kali. argmax menangkapnya 5 kali.

Seberapa baik 0,484? Dua penggaris untuk membacanya.

Skor kappa tidak punya satuan intuitif, jadi kami menaruhnya pada skala baku dan pada batas teoretis.

SKALA LANDIS & KOCH (1977)



Penggaris 1: skala baku

0,484 jatuh di kategori kesepakatan sedang. Kenaikan dari argmax memindahkan model yang sama dari batas bawah ke tengah kategori itu.

Penggaris 2: batas teoretis

Studi kembar Lykken & Tellegen (1996) memperkirakan sekitar separuh variasi kesejahteraan subjektif terkait faktor bawaan yang tidak diukur survei kesehatan mana pun. Plafon kami konsisten dengan itu.

Satu sel memikul 35,8% seluruh penalti.

Sumbangan tiap sel terhadap total penalti QWK, dalam persen.

		prediksi			
		1	2	3	4
aktual	1	0	28,89	5,58	1,31
	2	35,77	0	10,64	5,49
	3	1,52	3,42	0	1,51
	4	3,05	2,19	0,64	0

Sel merah adalah aktual 2 yang diprediksi 1.

64,7%

Porsi penalti yang datang hanya dari kebingungan kelas 1 dan 2

Keduanya memang berdekatan secara substantif. Membedakan "Sangat puas" dari "Puas" sebagian bersifat subjektif pada tingkat responden, dan kemungkinan besar tidak dapat dipisahkan lebih jauh dari variabel yang tersedia.

Galat berjarak tiga hanya menyumbang 4,36%.

Model ini menangkap kelas langka. argmax tidak sama sekali.

Presisi, recall, dan F1 per kelas pada prediksi out-of-fold.

Kelas	presisi	recall	F1	jumlah aktual	jumlah prediksi
1 Sangat puas	0,6689	0,7078	0,6878	42.968	45.468
2 Puas	0,6775	0,5909	0,6313	48.189	42.033
3 Tidak puas	0,2076	0,3847	0,2696	3.559	6.596
4 Sangat tidak puas	0,1753	0,2968	0,2204	893	1.512

Recall rendah, tapi tiap tangkapan bernilai besar

Penalti kuadratik membuat satu kelas 4 yang berhasil ditangkap menghapus penalti sembilan kali lipat. Kolom jumlah prediksi sengaja melebihi jumlah aktual: itulah harga keberanian yang dibayar dengan presisi.

Kalibrasi diperiksa, koreksi tidak diperlukan

Diagram reliabilitas mengikuti garis diagonal cukup dekat, sehingga Platt scaling maupun regresi isotonik tidak dipakai. Rata-rata lintas lima fold dan lima model sendiri sudah meredam sifat terlalu percaya diri boosting.


Tidak ada subkelompok yang ditinggalkan model ini.

Rata-rata skor bisa menyembunyikan kegagalan sistematis, jadi kami memecahnya per kelompok.


MENURUT JENIS KELAMIN



MENURUT KELOMPOK USIA



MENURUT TINGKAT PENDIDIKAN, SEPULUH TINGKAT




Rentang 0,3968 sampai 0,4909. Titik terendah adalah tingkat 2, dengan hanya 1.438 responden.

Bacaan. Selisih antar jenis kelamin hanya 0,0003. Variasi antar kelompok usia dan pendidikan sejalan dengan ukuran sampelnya, bukan dengan kegagalan sistematis pada satu segmen populasi.

Yang paling berpengaruh sejalan dengan literatur, bukan dengan artefak.

Penurunan QWK ketika satu kolom diacak, diukur pada subsampel dengan QWK acuan 0,83695.




Kenapa bobot survei muncul

survey_weight, pseudo_psu, dan pseudo_stratum adalah struktur pengambilan sampel. Ketiganya membawa informasi geografis dan demografis secara tidak langsung, jadi kehadirannya masuk akal, bukan kebocoran.

Tidak ada satu pun fitur dominan. Sinyalnya tersebar tipis, persis seperti yang diramalkan EDA.

Plafon ini milik data, bukan milik kami.

Pipeline dilatih ulang penuh pada 12, 25, 45, 70, dan 100 persen data.



$$\text{QWK} = 0,29209 + 0,01613 \cdot \ln(n)$$

R² kecocokan terhadap lima titik **0,9143**

Kenaikan per penggandaan data **+0,01118**


Target QWK	Baris dibutuhkan	Kelipatan	Setara waktu
0,49	213.000	2×	± 2 tahun survei
0,50	396.000	4×	± 4 tahun survei
0,55	8.790.000	92×	± 88 tahun survei
0,60	195.000.000	2.041×	± 1.950 tahun survei

Kurvanya masih melambat, jadi angka ini justru terlalu optimistis.

Enam peringkat teratas tidak dapat dibedakan secara statistik.

Bootstrap 400 kali atas matriks konfusi out-of-fold kami sendiri, pada irisan seukuran papan skor publik.

INTERVAL 95% · IRISAN 7.100 BARIS



Batang merah digambar dengan skala sumbu yang sama. Ia muat berkali-kali di dalam interval.

0,0050

sd QWK pada irisan seukuran seluruh data uji (23.666)

0,0105

sd QWK pada irisan seukuran papan skor publik (7.100)

0,7 σ

lebar enam peringkat berturut-turut, dalam satuan sd

Cara membacanya. Selisih di bawah sekitar 0,02 QWK pada papan skor publik belum melampaui dua simpangan baku, jadi urutan di kisaran itu lebih banyak ditentukan irisan data daripada metodologi.

BABAK VI

Bisa diulang, dan bisa dipakai.

Angka yang tidak dapat direproduksi bukan hasil. Angka yang tidak dapat dipakai bukan manfaat.

Artefak model 84 MB, dimuat ulang

Tujuh uji integritas submission

Keterbatasan yang kami akui sendiri

Prototipe berjalan di peramban

Satu eksekusi menghasilkan model, submission, dan angka di slide ini.

Seluruh sumber keacakan yang dapat dikendalikan sudah dikunci dan dicatat.

Yang dikunci

SEED	42
Seed per fold	0 sampai 4
PYTHONHASHSEED	diatur
Python	3.11.9
LightGBM	4.7.0
XGBoost	3.2.0
CatBoost	1.2.10

Artefak yang tersimpan

model_warkab.joblib	84,0 MB
Isi bundel	model, meta, ambang
Urutan 176 fitur	ikut disimpan
Verifikasi muat ulang	lulus
Total waktu eksekusi	135,1 menit

Tujuh uji integritas

- ✓ 23.666 baris
- ✓ Seluruh id unik
- ✓ Tidak ada nilai kosong
- ✓ Prediksi dalam {1,2,3,4}
- ✓ Tipe id integer
- ✓ Seluruh id uji mewakili
- ✓ Berkas model tersimpan

STABILITAS TERHADAP SEED PEMBAGIAN FOLD META

seed fold meta	QWK OOF	t ₁	t ₂	t ₃
7	0,48384	1,5648	2,0077	2,5742
202	0,48413	1,5617	1,9990	2,5861
999	0,48390	1,5609	1,9917	2,5680

0,00029
rentang QWK antar seed

0,00015
sd QWK antar seed

Enam keterbatasan, kami sebut sebelum ditanya.

Daftar ini ada di notebook, bukan hanya di slide.

Batas informasi

Kepribadian, hubungan sosial, dan rasa bermakna tidak terekam survei kesehatan.

Kelas 4 sangat kecil

Hanya 893 sampel latih, sehingga t_3 jadi ambang paling sensitif.

Ambang peka distribusi

Dioptimalkan pada distribusi latih. Pemeriksaan pola kosong menunjukkan risikonya kecil.

Ambiguitas kelas 1 dan 2

Sebagian bersifat subjektif pada tingkat responden, kemungkinan tidak sepenuhnya bisa dipelajari.

Determinisme tidak sempurna

Pustaka boosting multi-thread tidak menjamin hasil bit-identik. Selisih terukur sekitar 0,001 QWK.

Estimasi ambang tetap bervariasi

Reduksi variansi memperkecil, tidak menghilangkan. sd t_3 antar bootstrap 0,0392.

Setiap ketentuan panitia, dan letak pemenuhannya.


Pemetaan ini juga ada sebagai tabel di bagian 14 notebook.

Pasal	Ketentuan	Cara pemenuhan	Lokasi
B.1.a	Dilarang data eksternal	Hanya train_final.csv dan test_final.csv	Bagian 2
B.1.b	Bebas memilih pustaka	LightGBM, XGBoost, CatBoost, scikit-learn	Bagian 1
B.1.c	Dilarang pelabelan manual dan probing papan skor	Seluruh ambang dan pemilihan model dari OOF latih	Bagian 8, 9
B.1.d	Integritas tim	Dikerjakan internal tim	—
B.1.e	Transparansi metodologi	Tiap keputusan disertai alasan dan bukti empiris	Bagian 3, 5, 11
C	Alur end-to-end lengkap	Import, EDA, preprocessing, training, evaluasi, submission	Bagian 1 sampai 12
C	Random seed eksplisit	SEED 42, FOLD_SEEDS, PYTHONHASHSEED	Bagian 1, 7
C	Model tersimpan	model_warkab.joblib beserta verifikasi muat ulang	Bagian 12.1, 12.4
C	Seluruh output terlihat	Notebook dijalankan penuh sebelum dikumpulkan	Seluruh sel
D	Reproduksibilitas skor	Submission dihasilkan langsung oleh notebook ini	Bagian 12.2

Berkas submission dan berkas model berasal dari satu eksekusi yang sama, sehingga skor notebook dan skor papan peringkat berasal dari satu proses identik.

Dari notebook ke alat yang bisa dipakai.

Aturan keputusan yang sama persis, berjalan penuh di peramban, tanpa server.



Tiap kotak satu responden. Yang berwarna hangat adalah 4,7% yang dicari.

COBA SAAT PITCHING

lifescope-mikaeladikara-5555s-projects.vercel.app

- **Surrogate 440 pohon, 17 fitur**
QWK 0,46752, yaitu 96,5% dari pipeline penuh
- **Ambang dapat digeser langsung**
Seret t_3 pada histogram, jumlah tertangkap terhitung ulang
- **Tombol (i) di tiap istilah**
Rumus dan definisi muncul saat diklik, siap untuk tanya jawab

Yang berubah: dari satu angka agregat menjadi daftar bernama.

Survei melaporkan berapa persen. Alat ini menunjuk siapa saja, lalu mengurutkannya.

YANG TERSEDIA SEKARANG

4,7%

Satu angka agregat di laporan survei. Tidak memberi tahu siapa orangnya, jadi tidak ada yang bisa ditindaklanjuti.



YANG DIHASILKAN LIFESCOPE

4	2,932	Responden #1
4	2,790	Responden #2
4	2,738	Responden #3
3	2,445	Responden #4

Terurut menurut prioritas, siap dibagi ke petugas lapangan atau diekspor.

Model ini alat penapisan tingkat populasi, bukan diagnosis individual.

Empat langkah, masing-masing dengan syaratnya.

Kami menuliskan syaratnya karena melewatinya adalah cara model seperti ini gagal.

1

Penapisan retrospektif

Jalankan pada gelombang survei yang sudah ada.

Syarat: tidak ada. Bisa hari ini.

2

Prioritisasi tindak lanjut

Pakai peringkat $E[y]$, bukan label, untuk menyusun antrean.

Syarat: t_3 dikalibrasi untuk sensitivitas.

3

Instrumen 17 pertanyaan

Wawancara singkat menggantikan kuesioner penuh.

Syarat: validasi ulang pada populasi sasaran.

4

Tambah variabel

Kepribadian dan hubungan sosial adalah yang hilang.

Syarat: pengumpulan data baru.

Tiga saran yang kami pegang sendiri

1	Pakai untuk populasi, bukan individu	Sebaran $E[y]$ kelas 1 dan 2 bertumpang tindih lebar. Untuk seribu orang agregatnya andal.
2	Tambah variabel, bukan tambah model	Kurva belajar menunjukkan pengembalian dari algoritma sudah habis.
3	Baca 0,47 sampai 0,50 sebagai satu kelompok	Selisih di dalam kisaran itu lebih mencerminkan derau sampling daripada kualitas metodologi.

**Kami tidak mengejar angka.
Kami memetakan batasnya,
lalu berhenti tepat di sana.**

Setiap keputusan punya angka yang mendasarinya, dan setiap angka dapat dijalankan ulang dari notebook yang kami kumpulkan.

Tim Warkab

lifescope-mikaeladikara-5555s-projects.vercel.app

github.com/MikaelAdikara/DataQuest-Warkab

TIGA ANGKA UNTUK DIINGAT

+0,06269

dari aturan keputusan, tuas terbesar

0,9143

R² kurva belajar yang membuktikan plafonnya

0,7 σ

jarak enam peringkat papan skor

Terima kasih, kami siap menjawab pertanyaan.

Sepuluh pendekatan yang diuji lalu ditolak.

Hasil negatif kami laporkan selengkap hasil positif, karena ia menjelaskan kenapa arsitektur akhirnya sesederhana ini.

Pendekatan	Alasan ditolak	Bukti
Fitur komposit domain	Tidak ada perbaikan pada ablasi CV	Bagian 5.1
Konversi kode 7/8/9 menjadi NaN	Tidak ada perbaikan, kode membawa sinyal	Bagian 3.3, 5.1
Target encoding rumah tangga	Lift hanya +1,6pp, dan justru menurunkan skor	Bagian 3.5
Kolom id sebagai fitur	Spearman 0,006, tidak informatif	Bagian 3.6
argmax probabilitas	QWK jauh di bawah ambang batas ordinal	Bagian 9
MLP sebagai model utama	QWK di bawah seluruh model pohon	Bagian 7.1
Ambang batas titik tunggal	Selisih in-sample dan held-out paling besar	Bagian 9.1
Kalibrasi Platt atau isotonik	Diagram reliabilitas sudah mendekati diagonal	Bagian 9.2
Indikator tahun survei	Distribusi target stabil antar tahun	Bagian 3.8
Seleksi fitur agresif	Sinyal tersebar tipis, tidak ada fitur dominan	Bagian 3.7

Prinsip parsimoni. Menyertakan komponen yang tidak terbukti berkontribusi hanya menambah kompleksitas dan memperbesar risiko overfitting. Setiap penolakan didasarkan pada pengukuran.

Sebelas eksperimen di luar notebook, lengkap dengan angkanya.

Dijalankan selama pengembangan, tidak dimasukkan ke notebook karena memperpanjang eksekusi tanpa mengubah kesimpulan.

Eksperimen	Cakupan	QWK	Kesimpulan
Pencarian hyperparameter acak	28 konfigurasi LightGBM	0,465 – 0,467	Tidak ada yang menonjol
Rekonstruksi nilai hilang	3.030.768 sel dipulihkan	0,4755 – 0,4806	Datar di tiga tingkat
Pembobotan sampel	4 tingkat bobot minoritas	0,458 – 0,469	Menurun monoton
Self-training	Pseudo-label data uji	0,4735	Tidak menembus
Pembobotan survei	survey_weight sebagai bobot latih	0,4726	Tidak menembus
Bagging 9 model	6 LightGBM + 3 CatBoost	0,4820	Di bawah stacking
Blending 25 kandidat	Greedy, z-score, rank-average	0,4834 – 0,4839	Setara yang terbaik
Vektor nilai kelas terlatih	Mengganti bobot (1,2,3,4)	0,4835	Optimum tetap (1,2,3,4)
Aturan linear pada simpleks	argmax(W·p + b), 20 parameter	0,4744	Di bawah ordinal
Model fondasi tabular	TabPFN v2 pada GPU	tidak selesai	85 menit per bag
Ambang batas per segmen	Tahun, kesehatan, usia, silangannya	tampak naik	Terbukti overfit

78 kolom dapat direkonstruksi di atas 95% akurat, lima di antaranya sempurna. Memulihkan seluruh sel yang hilang tidak menaikkan QWK sama sekali: yang dipulihkan adalah redundansi, bukan sinyal.

Daftar pustaka.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of KDD 2016.

Cohen, J. (1968). Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. Psychological Bulletin, 70(4).

Efron, B. (1979). Bootstrap methods: Another look at the jackknife. The Annals of Statistics, 7(1).

Frank, E., & Hall, M. (2001). A simple approach to ordinal classification. ECML 2001, LNCS 2167.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5).

Huber, P. J. (1964). Robust estimation of a location parameter. The Annals of Mathematical Statistics, 35(1).

Kahneman, D., & Deaton, A. (2010). High income improves evaluation of life but not emotional well-being. PNAS, 107(38).

Ke, G., dkk. (2017). LightGBM: A highly efficient gradient boosting decision tree. NeurIPS 2017.

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1).

Lykken, D., & Tellegen, A. (1996). Happiness is a stochastic phenomenon. Psychological Science, 7(3).

OECD. (2013). OECD Guidelines on Measuring Subjective Well-being. OECD Publishing, Paris.

Prokhorenkova, L., dkk. (2018). CatBoost: Unbiased boosting with categorical features. NeurIPS 2018.

Wolpert, D. H. (1992). Stacked generalization. Neural Networks, 5(2).

World Health Organization. (2023). Depressive disorder (depression), fact sheet.