

Membaca Skala, Bukan Menebak Kelas

Prediksi kepuasan hidup dari 176 variabel survei, dirancang untuk satu metrik.

DISTRIBUSI TARGET · 95.609 BARIS LATIH



0,48425

QWK out-of-fold

6

Keluarga algoritma

176

Fitur mentah

42

Seed, dikunci

0

Baris data eksternal

Tebakan teraman di kompetisi ini bernilai tepat nol.

50,402%

Akurasi bila menebak kelas mayoritas untuk semua orang

0,000000

QWK untuk tebakan yang sama persis

Metrik lomba ini tidak memberi imbalan pada tebakan aman. Seluruh strategi kami turun dari satu fakta itu.

QWK menghitung jarak, bukan salah atau benar.

Bobot penaltinya kuadratik, jadi seberapa jauh melesetnya yang dihukum.


		prediksi			
		1	2	3	4
aktual	1	0	1	4	9
	2	1	0	1	4
	3	4	1	0	1
	4	9	4	1	0

Menebak kelas 4 sebagai 1 dihukum **9 kali** lebih berat daripada menebak 2 sebagai 1.

Maka targetnya skala, bukan empat kotak terpisah.

Kami memprediksi satu titik pada skala, lalu memotongnya dengan tiga ambang.


$$E[y] = \sum p_k \cdot k$$



argmax hanya berani menebak kelas 3 atau 4 pada 0,70% baris. Proporsi sebenarnya 4,71%. **Aturan ambang menaikkannya ke 8,48%.**

89,9% perbaikan kami datang dari aturan keputusan.

Enam baseline dijalankan penuh, bukan diestimasi, agar tiap komponen terpisah.




+0,06269 baris 4 ke 5, hanya aturannya yang berubah

+0,00708 lima model lagi, stacking, dan studi ambang

Enam keluarga algoritma mendarat di titik yang sama.

Bias induktifnya sangat berbeda. Hasilnya terpaut 0,0033 QWK.



Sumbu dipotong pada 0,42 agar rentangnya terlihat.

0,974

Korelasi prediksi antar model pohon

+0,00455

Sumbangan meta-learner di atas yang terbaik

Ketika kelas fungsi yang berbeda mendarat di titik sama, dindingnya milik data.

Kebocoran paling menggoda: kami ukur dulu, baru buang.

61,3% baris uji punya anggota rumah tangga yang labelnya ada di data latih.

Label anggota rumah tangga lain	y = 1	y = 2	y = 3	y = 4
menjawab 1, Sangat puas	0,4654	0,4903	0,0354	0,0089
menjawab 2, Puas	0,4347	0,5200	0,0360	0,0093
menjawab 3, Tidak puas	0,4280	0,4902	0,0712	0,0106
menjawab 4, Sangat tidak puas	0,4294	0,5068	0,0425	0,0212

44,9% → 46,5%

+1,6 poin persentase

Itu seluruh lift yang ditawarkan struktur rumah tangga.

Kami membuangnya berdasarkan besaran sinyalnya, sebelum melihat skor apa pun.

Tiga juta sel dipulihkan. Skor tidak bergerak.

Kami melatih satu model rekonstruksi per kolom, memakai kolom lain di dataset resmi.

3.030.768

sel ter-mask dipulihkan seluruhnya

78

kolom pulih di atas 95%, lima di antaranya sempurna

0,4755 – 0,4806

QWK pada tiga tingkat pemulihan

Yang dapat dipulihkan adalah redundansi, bukan sinyal.

Nilai yang bisa ditebak 99% akurat dari kolom lain, menurut definisi, tidak membawa informasi baru.

Kami membangun alat untuk membunuh ide kami sendiri.

Ambang batas per segmen terdengar benar, dan skornya memang naik.

YANG TERLIHAT

QWK naik

Makin banyak segmen, makin tinggi skornya pada himpunan tempat ambang dipasang.

YANG SEBENARNYA TERJADI

Held-out turun

Uji split-half: tiap parameter tambahan menaikkan in-sample dan menurunkan held-out.

Ditolak. Tanpa uji split-half, konfigurasi ini akan terlihat sebagai perbaikan terbesar kedua dalam proyek, dan akan merugikan kami di data uji.

Tidak ada kriteria data latih yang bisa menebak pemenang.

Dua puluh konfigurasi yang sama-sama masuk akal, diuji dengan dua kriteria.

Kriteria seleksi	Korelasi dengan kinerja pada data uji
QWK out-of-fold	$\approx 0,08$
QWK held-out, uji split-half	$\approx 0,16$

0,003

Rentang QWK di antara kedua puluh konfigurasi itu

Mengejar skor tertinggi pada rentang ini bukan optimasi. Itu memilih derau.

Karena itu kombinasi dan strategi ambang kami tetapkan di muka, berdasarkan sifat penduga, bukan skor.


Enam belas jalan buntu, lengkap dengan angkanya.

Hasil negatif kami laporkan selengkap hasil positif.

Eksperimen	Cakupan	QWK	Kesimpulan
Pencarian hyperparameter acak	28 konfigurasi LightGBM	0,465 – 0,467	Tidak ada yang menonjol
Rekonstruksi nilai hilang	3.030.768 sel dipulihkan	0,4755 – 0,4806	Datar di tiga tingkat
Pembobotan sampel	4 tingkat bobot minoritas	0,458 – 0,469	Menurun monoton
Self-training	Pseudo-label data uji	0,4735	Tidak menembus
Pembobotan survei	survey_weight sebagai bobot	0,4726	Tidak menembus
Bagging 9 model	6 LightGBM + 3 CatBoost	0,4820	Di bawah stacking
Blending 25 kandidat	Greedy, z-score, rank-avg	0,4834 – 0,4839	Setara yang terbaik
Vektor nilai kelas terlatih	Mengganti bobot (1,2,3,4)	0,4835	Optimum tetap (1,2,3,4)
Aturan linear pada simpleks	argmax($W \cdot p + b$)	0,4744	Di bawah ordinal
Model fondasi tabular	TabPFN v2 pada GPU	tidak selesai	85 menit per bag
Ambang batas per segmen	Tahun, kesehatan, usia	tampak naik	Terbukti overfit
Fitur komposit	Indeks gabungan buatan	–0,00090	Dibuang
Kode 7/8/9 jadi NaN	Penanganan non-respons	+0,00111	Di bawah derau
Target encoding rumah tangga	11.620 rumah tangga	lift +1,6pp	Ditolak sebelum dipakai

Plafon ini milik data, bukan milik kami.

Pipeline dilatih ulang pada 12, 25, 45, 70, dan 100 persen data.



$$\text{QWK} = 0,29209 + 0,01613 \cdot \ln(n)$$

0,9143

R^2 kecocokan terhadap lima titik terukur

+0,01118

Kenaikan per penggandaan data

Kurvanya masih melambat, jadi angka itu terlalu optimistis.

QWK 0,60 menuntut 195 juta baris.

Menyelesaikan persamaan kurva belajar untuk n pada beberapa target.

Target QWK	Baris dibutuhkan	Kelipatan data kini	Setara waktu pengumpulan
0,49	213.000	2×	± 2 tahun survei
0,50	396.000	4×	± 4 tahun survei
0,55	8.790.000	92×	± 88 tahun survei
0,60	195.000.000	2.041×	± 1.950 tahun survei

Klaim kami, dan ini dapat difalsifikasi: dari dataset resmi saja, QWK jauh di atas 0,50 tidak dapat dicapai dengan pemodelan yang lebih baik. Jalankan kurva belajar yang sama, koefisiennya akan keluar sama.

Enam peringkat teratas tidak dapat dibedakan.

Bootstrap 400 kali atas matriks konfusi out-of-fold kami sendiri.



0,0050

sd pada irisan seukuran data uji

0,0105

sd pada irisan seukuran papan skor

0,7 σ

jarak enam peringkat berturut-turut

Yang kami periksa sebelum menyebutnya selesai.

Dua hal terpisah: apakah modelnya benar, dan apakah siapa pun bisa mengulanginya.

Validasi

- **35,8%**
penalti berasal dari satu sel: aktual 2 diprediksi 1
- **0,4839 / 0,4836**
QWK per jenis kelamin, diperiksa juga per usia dan wilayah
- **0,4726**
QWK saat survey_weight dipakai sebagai bobot latih, jadi tidak dipakai


Reproduksibilitas

- **seed 42**
dikunci di fold, enam model, bootstrap, dan kurva belajar
- **84 MB**
joblib memuat model, meta, ambang, dan urutan 176 fitur
- **135 menit**
eksekusi penuh menghasilkan submission yang identik

Batasan yang kami akui: pustaka boosting multi-thread tidak menjamin hasil bit-identik, selisihnya terukur sekitar 0,001 QWK.

Dari notebook ke alat yang bisa dipakai.

Aturan keputusan yang sama, berjalan penuh di peramban, tanpa server.



Tiap kotak satu responden. Yang berwarna hangat adalah 4,7% yang dicari.

COBA SAAT PITCHING

lifescope-mikaeladikara-5555s-projects.vercel.app

- Tujuannya terbaca sekali lihat

Grid 200 kotak pada proporsi kelas sebenarnya.
- Ambang dapat digeser langsung

Seret t_3 di histogram, jumlah tertangkap terhitung ulang.
- Tombol (i) di tiap istilah

Rumus dan definisi muncul saat diklik, siap untuk tanya jawab.

Satu angka agregat berubah jadi daftar bernama.

Itu seluruh manfaatnya, dan itu yang selama ini hilang.

YANG TERSEDIA SEKARANG

4,7%

Satu baris di laporan survei. Tidak memberi tahu siapa orangnya, jadi tidak bisa ditindaklanjuti.



YANG LIFESCOPE HASILKAN

4	2,932	Responden #1
4	2,790	Responden #2
4	2,738	Responden #3
3	2,445	Responden #4

Terurut menurut prioritas, siap dibagi ke petugas atau diekspor.

Model ini alat penapisan tingkat populasi, bukan diagnosis individual.

Empat langkah, masing-masing dengan syaratnya.

Kami menuliskan syaratnya karena melewatinya adalah cara model seperti ini gagal.

1

Penapisan retrospektif

Jalankan pada gelombang survei yang sudah ada.

Syarat: tidak ada. Bisa hari ini.

2

Prioritisasi tindak lanjut

Pakai peringkat $E[y]$, bukan label, untuk menyusun antrean.

Syarat: t_3 dikalibrasi untuk sensitivitas.

3

Instrumen 17 pertanyaan

Wawancara singkat menggantikan kuesioner penuh.

Syarat: validasi ulang pada populasi sasaran.

4

Tambah variabel

Kepribadian dan hubungan sosial adalah yang hilang.

Syarat: pengumpulan data baru.

Langkah 1 bisa dilakukan hari ini. Langkah 4 tidak bisa dipercepat oleh algoritma apa pun.

Tiga saran yang kami pegang sendiri.

Untuk pemakaian, untuk pengembangan, dan untuk membaca papan skor.

1

Pakai untuk populasi, bukan individu

Sebaran $E[y]$ kelas 1 dan 2 bertumpang tindih lebar. Untuk seribu orang agregatnya andal.

2

Tambah variabel, bukan tambah model

Kurva belajar menunjukkan pengembalian dari algoritma sudah habis. Satu instrumen kepribadian berpotensi melampaui seluruh notebook ini.

3

Baca 0,47 sampai 0,50 sebagai satu kelompok

Selisih di dalam kisaran itu lebih mencerminkan derau sampling daripada kualitas metodologi.

**Kami tidak mengejar angka.
Kami memetakan batasnya,
lalu berhenti tepat di sana.**

Setiap keputusan punya angka yang mendasarinya, dan setiap angka dapat dijalankan ulang dari notebook yang kami kumpulkan.

Tim Warkab

lifescope-mikaeladikara-5555s-projects.vercel.app

TIGA ANGKA UNTUK DIINGAT

+0,06269

dari aturan keputusan, tuas terbesar

0,9143

R² kurva belajar yang membuktikan plafonnya

0,7 σ

jarak enam peringkat papan skor

Terima kasih, kami siap menjawab pertanyaan.