

Membaca Skala, Bukan Menebak Kelas

Menemukan lebih awal siapa yang paling perlu ditolong, dari survei kesehatan yang sudah ada.

DISTRIBUSI TARGET · 95.609 BARIS LATIH



0,48425

QWK out-of-fold

6

Keluarga algoritma

176

Fitur mentah

42

Seed, dikunci

0

Baris data eksternal

SEBELUM ADA MODEL, ADA MANUSIA

Orang yang tidak puas dengan hidupnya jarang terlihat, sampai terlambat.

Ketidakpuasan hidup yang rendah dan berkepanjangan memprediksi umur yang lebih pendek (Diener & Chan, 2011) dan risiko bunuh diri hingga 20 tahun kemudian (Koivumaa-Honkanen dkk., 2001). Masalahnya bukan tidak bisa dideteksi. Masalahnya, tidak ada yang membacanya lebih awal.

± 280 juta

orang di dunia hidup dengan depresi

WHO, 2023

± 703.000

kematian akibat bunuh diri setiap tahun

WHO, 2021

9%


penderita depresi di Indonesia yang berobat, dari prevalensi 6,1%

Riskesdas, 2018

Proyek ini dimulai dari satu pertanyaan: bisakah kita menemukan mereka lebih awal, dari data yang sudah rutin dikumpulkan?

Datanya sudah ada. Yang belum ada adalah siapa orangnya.

Survei kesehatan rutin menanyakan kepuasan hidup, tetapi hasilnya hanya berakhir sebagai satu persentase.



Tujuan proyek. Mengubah jawaban survei yang sudah ada menjadi daftar prioritas orang yang paling mungkin tidak puas dengan hidupnya, supaya bantuan datang lebih awal.

Layanan kesehatan primer

Puskesmas dan dinas kesehatan memprioritaskan kunjungan dan rujukan konseling dari survei yang sudah berjalan.

Program kesejahteraan

HR perusahaan dan penyedia asuransi menjangkau peserta berisiko lebih awal lewat program wellbeing.

Kebijakan dan riset

Instrumen 17 pertanyaan yang murah untuk memetakan kesejahteraan per wilayah dan memantau intervensi.

"Semua baik-baik saja": akurasi 50,4%, tak menemukan siapa pun.

Karena itu kami tidak mengejar akurasi. Metrik harus menghukum kesalahan yang paling mahal di dunia nyata.

50,402%

akurasi jika semua ditebak "Puas"

0 dari 4.452

orang tidak puas yang ditemukan

0,00000

nilai QWK untuk tebakan itu

Akurasi memberi nilai tinggi pada model yang tidak berguna. Quadratic Weighted Kappa, metrik yang kami optimalkan, memberinya nol.

KENAPA QWK COCOK DENGAN DUNIA NYATA

Menempatkan orang yang sangat tidak puas sebagai sangat puas **dihukum 9 kali** lebih berat daripada meleset satu tingkat. Itu persis biaya sebuah skrining yang meloloskan kasus berat, dibanding sekadar salah menilai orang yang cukup puas sebagai puas.

Kappa ini juga mengoreksi kebetulan, jadi model tidak bisa menang dengan menebak proporsi.

DATA YANG KAMI OLAH

Sangat puas

42.968

Puas

48.189

Tidak puas

3.559

Sangat tidak puas

893

Berkas	Ukuran
train_final.csv	95.609 × 179
test_final.csv	23.902 × 178
Fitur numerik	176
Tahun survei	2021 sampai 2024
id unik di uji	23.666
Data eksternal	0 baris

Enam hal yang membedakan pipeline kami dari pendekatan standar.

Setiap keunggulan punya angka pembuktian, dan setiap angka akan muncul lagi di slide berikutnya.

Aspek	Pendekatan standar	Pipeline kami	Bukti
Aturan keputusan	argmax, mengejar akurasi	Nilai harapan + 3 ambang ordinal	+0,06269 QWK pada model yang sama
Dasar keputusan	Fitur ditambah tanpa uji	10 temuan EDA → 10 keputusan, lewat ablasi	13 fitur komposit dibuang, selisih −0,00090
Kebocoran data	Sinyal menggiurkan langsung dipakai	Diukur dulu, lalu ditolak	Encoding rumah tangga: lift hanya +1,6pp
Pemilihan konfigurasi	Skor validasi tertinggi	Paling stabil lewat uji split-half	Held-out 0,48106 vs titik tunggal 0,48083
Kapan berhenti	Terus tuning tanpa batas	Plafon dikuantifikasi	R ² 0,9143; QWK 0,60 butuh 195 juta baris
Siap dipakai	Berhenti di notebook	Reproduksibel dan ada produknya	Rentang seed 0,00029; demo jalan di peramban

Keunggulan terbesarnya bukan skor, melainkan kepercayaan. Selisih enam peringkat teratas papan skor hanya 0,7 simpangan baku. Di rentang itu, yang membedakan tim adalah apakah hasilnya stabil di data baru, bisa diulang, dan bisa dipakai.

QWK menghitung jarak, jadi targetnya skala, bukan empat kotak.

Bobot penaltinya kuadratik. Keputusan optimal untuk galat kuadratik adalah nilai harapan, bukan modus.

$$\kappa = 1 - \sum w_{ij} O_{ij} / \sum w_{ij} E_{ij}$$


$$w_{ij} = (i - j)^2 / 9$$

O matriks konfusi teramati, E matriks ekspektasi di bawah independensi.
Diimplementasikan ulang secara tervektorisasi, 47 kali lebih cepat, selisih terhadap scikit-learn $4,44 \times 10^{-16}$ pada 200 uji acak.

		prediksi			
		1	2	3	4
aktual	1	0	1	4	9
	2	1	0	1	4
	3	4	1	0	1
	4	9	4	1	0

Menebak kelas 4 sebagai 1 dihukum 9 kali lebih berat daripada menebak 2 sebagai 1.

$$E[y] = \sum p_k \cdot k$$



Tiga ambang itulah keputusan akhir pipeline. Seluruhnya diestimasi dari prediksi out-of-fold data latih, tidak pernah dari data uji.


Kenapa masalah ini sulit: empat akar, empat jawaban.

Setiap akar menentukan satu babak berikutnya. Deck ini disusun mengikuti pohon ini.



EDA 1 - Target timpang, kosong merata, kode 7/8/9 bermakna.

Tiga temuan pertama, masing-masing langsung menjadi keputusan desain.



EDA 2 - Sinyalnya monoton, tersebar tipis, dan stabil empat tahun.

Tiga temuan yang menentukan jenis model, jumlah fitur, dan cakupan waktu.

3.4 · PREDIKTOR TERKUAT

Monoton, jadi layak dibaca sebagai skala

general_health_status

0,959

depression_frequency

0,896

difficulty_self_care

0,678

difficulty_using_hands

0,676

difficulty_social_activ.

0,665

anxiety_frequency

0,560

food_security_4cat

0,538

Rentang rata-rata target antar tingkat variabel.

Kesehatan memburuk, depresi makin sering, pangan makin rapuh: rata-rata target naik konsisten tanpa pembalikan.

Implikasi: tambah regresi Huber dan dekomposisi biner kumulatif di samping klasifikasi.

3.7 · STRUKTUR KORELASI

Tidak ada fitur dominan

0,361

korelasi tertinggi satu fitur ke target

0,037

median korelasi antar fitur

17

pasangan fitur $|p| > 0,9$

14.667

pasangan diperiksa

data_year · survey_year

1,000

children_in_family · _household

0,998

ever_used_ecigarette · status

0,997

cancer_ever · types_count

0,981

Redundansi terpusat pada pasangan yang memang kembar. Sisanya membawa sinyal kecil masing-masing.

Implikasi: seleksi fitur agresif ditolak, seluruh 176 fitur dipertahankan.

3.8 · STABILITAS ANTAR TAHUN

Melintasi pandemi, perilakunya sama

Tahun	n	rata-rata	% kls 3+4
2021	21.464	1,5914	5,25%
2022	20.417	1,6105	4,53%
2023	21.849	1,6153	4,49%
2024	24.230	1,6070	4,35%

0,0239

total pergerakan rata-rata target selama empat tahun; proporsi tahun di latih dan uji nyaris identik


Implikasi: satu model untuk seluruh periode. Indikator tahun dan model per tahun diuji lalu ditolak.

EDA 3 · Penentu terbesar tak terekam, dua kebocoran ditolak.

Peta kekuatan sinyal per domain, lalu dua jebakan yang diukur sebelum dibuang.

3.9 · PETA SINYAL PER DOMAIN

Korelasi Spearman maksimum terhadap target



Tidak terekam survei

- Kepribadian
- Hubungan sosial
- Rasa bermakna
- Adaptasi hedonik

Literatur menempatkan keempatnya di depan. Lykken & Tellegen (1996): sekitar separuh variasi kesejahteraan terkait faktor bawaan.

Implikasi: sebagian besar variasi target berada di luar jangkauan instrumen, bukan algoritma. Ini landasan analisis plafon.

3.5 DAN 3.6 · DUA JEBAKAN KEBOCORAN

Diukur dulu, lalu dibuang sebelum melihat skor

Target encoding rumah tangga · 61,3% baris uji punya anggota berlabel di data latih

Anggota lain menjawab	P(y = 1)
1 Sangat puas	0,4654
2 Puas	0,4347
3 Tidak puas	0,4280
4 Sangat tidak puas	0,4294

44,9% → 46,5%: lift hanya +1,6 poin. Encoding OOF lengkap justru menurunkan QWK.

Kolom id sebagai fitur

Spearman(id, target)	0,00595
Rata-rata per 20 bin id	1,5925 – 1,6251
Marginal	1,6065

Implikasi: household_id dan id dibuang. Temuan sampingan: id uji tidak unik, submission harus 23.666 baris.

Tiap keputusan desain terlacak ke satu temuan EDA.

Tidak ada keputusan yang diambil karena kebiasaan.

TEMUAN EDA	ARTINYA	KEPUTUSAN DESAIN
Target timpang 44,9 / 50,4 / 3,7 / 0,9	→ Baseline QWK nol meski akurasi 50,4%	→ Optimasi ambang, bukan argmax
QWK berbobot kuadratik	→ Galat berjarak jauh dihukum 9 kali	→ Perlakuan ordinal lewat nilai harapan
Kosong 14,4% sel, pola latih sama dengan uji	→ Tidak ada pergeseran distribusi	→ Tanpa imputasi, pohon menangani NaN
Kode 7/8/9 punya rata-rata target berbeda	→ Non-respons membawa sinyal	→ Kode dipertahankan apa adanya
Prediktor kuat bersifat monoton	→ Struktur ordinal nyata pada fitur	→ Regresi Huber dan dekomposisi kumulatif
Lift antar anggota rumah tangga +1,6pp	→ Kepuasan hidup sangat individual	→ household_id dibuang
Spearman(id, target) = 0,006	→ Tidak ada kebocoran urutan	→ id dibuang dari fitur
Median korelasi antar fitur 0,037	→ Seleksi fitur agresif merugikan	→ Seluruh 176 fitur dipertahankan
Rata-rata target bergerak 0,0239 antar tahun	→ Tidak ada pergeseran temporal	→ Satu model untuk seluruh periode
Domain psikososial tidak terekam	→ Sebagian besar variasi tak teramati	→ Landasan analisis plafon

Tujuh keputusan preprocessing, lalu 13 fitur komposit yang kami buang.

Setiap keputusan punya dasar yang bisa diperiksa. Fitur tambahan harus lolos ablasi dulu.

Keputusan	Pilihan	Dasarnya
Nilai kosong	Tetap NaN	Pohon belajar arah cabang sendiri
Kode 7 / 8 / 9	Apa adanya	Non-respons membawa sinyal
Skala model pohon	Tidak ada	Invarian transformasi monoton
Skala untuk MLP	Quantile + median	Jaringan saraf butuh input normal
household_id	Dibuang	Lift antar anggota +1,6pp
id	Dibuang	Spearman ke target 0,006
Encoding kategorikal	Tidak perlu	Semua kolom sudah kode numerik


13 FITUR KOMPOSIT YANG DIBANGUN

n_disease · n_difficulty · n_cost_barrier · n_mental · n_income_src · n_missing · sev_anxiety · sev_depression · sev_mental · sev_food · health_x_mental · poverty_x_health · bmi

Beban penyakit, keterbatasan fungsional, hambatan biaya, keparahan mental, ketahanan pangan, disusun dari pengelompokan data dictionary.

5.1 · ABLASI, CV 3-FOLD IDENTIK, 297 DETIK

Selisih terhadap fitur mentah saja



Kedua selisih lebih kecil dari 0,0012 QWK, setara derau antar fold.

Keputusan: fitur mentah saja. Pohon dengan 176 fitur sudah merekonstruksi sendiri interaksi semacam jumlah penyakit lewat kombinasi percabangan. Fitur komposit hanya mengulang informasi dan memperbesar risiko overfitting.

Satu pembagian fold untuk semua model, satu metrik yang terverifikasi.

Fondasi yang membuat stacking sah dan estimasi out-of-fold tetap tak bias.

6.2 · IMPLEMENTASI QWK

Ditulis ulang, dibuktikan setara

Selisih maks. vs sklearn	$4,44 \times 10^{-16}$
Uji acak	200
qwk_fast	43 μ s
cohen_kappa_score	2.029 μ s

47 ×




lebih cepat, yang membuat studi ambang 25 menit menjadi mungkin

Implikasi: metrik yang dioptimalkan identik dengan metrik panitia.

7 · DESAIN VALIDASI

StratifiedKFold 5, random_state 42

Seed model per fold	0, 1, 2, 3, 4
Latih per fold	76.487 / 76.488
Validasi per fold	19.121 / 19.122

fold 0	
fold 1	
fold 2	
fold 3	
fold 4	

Fold identik untuk keenam model adalah prasyarat stacking. Stratifikasi menjaga proporsi kelas langka di setiap fold.

Implikasi: ambang dan pemilihan model hanya dari OOF latih, memenuhi larangan probing B.1.c.

6.3 · DARI PROBABILITAS KE LABEL

Tiga langkah deterministik

- 1 Rata-ratakan p**
lima model pohon × lima fold, matriks 4 kelas
- 2 Hitung $E[y] = \sum p_k \cdot k$**
satu bilangan kontinu per responden
- 3 Potong dengan $t_1 < t_2 < t_3$**
label akhir 1, 2, 3, atau 4

$E[y]$ juga memberi urutan prioritas kontinu, yang nanti dipakai prototipe untuk menyusun daftar tindak lanjut.

Implikasi: keluaran tetap label diskret, tetapi keputusannya menghormati jarak antar kelas.

Enam keluarga algoritma, dipilih berbeda, mendarat di titik yang sama.

Spesifikasi, landasan literatur, dan QWK out-of-fold masing-masing, dengan fold yang identik.

Model	Keluarga	Sudut pandang	Konfigurasi inti	Landasan	QWK OOF	Akurasi
ord	Dekomposisi kumulatif	Tiga model $P(y > k)$	3×1.200 pohon, lr 0,03	Frank & Hall 2001	0,48114	0,62820
xgb	Boosting level-wise	Regularisasi berbeda	1.200 pohon, lr 0,04, depth 8	Chen & Guestrin 2016	0,48067	0,62518
cat	Ordered boosting	Bias prediksi berbeda	1.800 iterasi, lr 0,05, depth 8	Prokhorenkova dkk. 2018	0,47982	0,62364
reg	Regresi Huber	Target skala kontinu	1.500 pohon, lr 0,03	Huber 1964	0,47918	0,62929
lgb	Boosting leaf-wise	Klasifikasi 4 kelas	1.500 pohon, lr 0,028, 127 daun	Ke dkk. 2017	0,47847	0,63121
mlp	Jaringan saraf	Batas keputusan mulus	Input ternormalisasi kuantil	MLP scikit-learn	0,44466	0,59741

0,00267

rentang QWK kelima model pohon

0,974

korelasi rata-rata prediksi antar model pohon

52,2 menit

melatih 6 model $\times$ 5 fold, CPU 12 core

Ketika kelas fungsi berbeda mendarat di titik sama, dindingnya milik data.

reg dan ord ada karena temuan monotonisitas EDA. Gradient boosting berakar pada Friedman (2001); seluruh pohon memakai subsample 0,8, colsample 0,4, reg_lambda 10. MLP tertinggal, wajar untuk data tabular berdimensi menengah, sehingga hanya dipakai sebagai pembanding keragaman.

Kombinasi ditetapkan di muka, ambang dicari dua tahap.

Empat kandidat pada matriks probabilitas OOF 95.609×24 , lalu tiga bilangan yang menjadi keputusan akhir.

Kandidat kombinasi	QWK OOF	t ₁	t ₂	t ₃
rata-rata lima model pohon	0,48517	1,5543	2,0027	2,3936
regresi logistik sebagai meta	0,48398	1,5601	2,0033	2,5525
rata-rata keenam model	0,48361	1,5524	2,0067	2,4103
LightGBM sebagai meta	0,48307	1,5591	2,0525	2,5309

8.1 · DUA ALASAN, DITETAPKAN SEBELUM HASIL DILIHAT

- 1. Rata-rata sederhana, bukan meta-learner.** Tidak punya parameter yang bisa menempel pada derau, dan model dasar sudah berkorelasi 0,974. Meta-learner menambah risiko tanpa menambah informasi.
- 2. MLP dikeluarkan.** QWK tunggalnya jelas di bawah lima model pohon, dan rata-rata tanpa bobot memberi porsi sama ke tiap anggota.

Keduanya dapat diperiksa tanpa data uji. Setelah dihitung, pilihan itu juga tertinggi di OOF, jadi disiplin a priori tidak mengorbankan skor. Sumbangan di atas model dasar terbaik: +0,00403 (Wolpert 1992, stacked generalization).

9 · OPTIMASI AMBANG

Grid kuantil, lalu pencarian koordinat

Grid $45 \times 32 \times 26$ titik	0,48446
Setelah pencarian koordinat	0,48517
Waktu penghalusan	48 detik

t ₁	t ₂	t ₃
1,5543	2,0027	2,3936
kelas 1 2	kelas 2 3	kelas 3 4

Grid kuantil menjamin cakupan seluruh rentang, pencarian koordinat menajamkan di sekitar optimum. Ambang final memakai rata-rata bootstrap dari studi estimasi, bukan titik tunggal ini.

89,9% perbaikan datang dari aturan keputusan, bukan dari model.

Akurasi turun, QWK naik. Enam baseline dijalankan penuh agar tiap komponen terpisah.

MODEL SAMA, ATURAN BERBEDA

argmax lawan nilai harapan + ambang

Strategi	QWK	Akurasi
argmax probabilitas	0,42460	0,66943
E[y] + ambang	0,48517	0,63258

PORSI LABEL KELAS 3 (ORANYE) DAN 4 (MERAH)

aktual  4,65%

argmax  0,96%

E[y] + ambang  8,58%


+0,06057

dari satu perubahan aturan keputusan pada stacking

argmax nyaris tidak pernah memilih kelas 3 dan 4 karena posteriornya jarang tertinggi, sehingga setiap responden sangat tidak puas menjadi galat penalti 9.

10.4 · DEKOMPOSISI BASELINE

Dari mana perbaikan sebenarnya datang



+0,06269

baris 4 → 5: hanya aturan berubah

+0,00708

baris 5 → 6: lima model, stacking, studi ambang

Baris 3 di bawah pohon menandakan hubungan fitur dan target memang non-linear, jadi model pohon bukan pilihan gaya.

Kriteria yang benar bukan skor tertinggi, melainkan yang paling stabil.

Lima strategi estimasi ambang, uji split-half sebagai wasit, dan satu ide kami sendiri yang terbukti overfit.

Strategi ambang	QWK OOF	in-sample	held-out	selisih
a. titik tunggal	0,48517	0,48688	0,48083	0,00606
b. rata-rata bootstrap (final)	0,48425	0,48625	0,48106	0,00519
c. rata-rata subsample 80%	0,48419	0,48654	0,48100	0,00554
d. cocok distribusi kelas	0,47413	0,47650	0,47206	0,00444
e. objektif dihaluskan	0,48435	—	—	—

SIMPANGAN BAKU AMBANG ANTAR 25 BOOTSTRAP

t ₁		0,0108
t ₂		0,0134
t ₃		0,0392

Keputusan: rata-rata bootstrap (Efron 1979). Strategi a menang di OOF karena memang itu definisinya, lalu kalah di held-out. Bootstrap menaruh ambang di pusat dataran tinggi. t₃ hampir 4 kali lebih goyah dari t₁ karena kelas 4 hanya 893 sampel. Kami melepas 0,0009 pada angka yang dilaporkan demi +0,00023 di held-out.

OVERFIT YANG KAMI TANGKAP SENDIRI

Ambang per segmen: QWK naik, held-out turun

Segmentasi per tahun, status kesehatan, usia, dan silangannya. Tiap parameter tambahan menaikkan in-sample dan menurunkan held-out secara monoton. Tanpa split-half, ini tampak sebagai perbaikan terbesar kedua.

Ditolak.


A.3 · 20 KONFIGURASI MASUK AKAL

Tidak ada kriteria latih yang memandu

Korelasi QWK OOF ke kinerja uji	≈ 0,08
Korelasi held-out ke kinerja uji	≈ 0,16
Rentang QWK 20 konfigurasi	0,003
Mengejar skor tertinggi di rentang ini adalah memilih derau.	

Demo · LifeScope mengubah jawaban survei menjadi daftar prioritas.

Metodologi tadi, kini bekerja: skrining satu orang, nilai satu kohort, dan geser ambang sesuai kapasitas layanan.



SEKARANG

4,7%

Angka agregat laporan survei.
Tidak memberi tahu siapa
orangnya.

DENGAN LIFESCOPE

2,932 Responden #1
2,790 Responden #2
2,738 Responden #3
2,445 Responden #4

Terurut menurut $E[y]$, siap dibagi
atau diekspor.

COBA SAAT PITCHING

lifescope-mikaeladikara-5555s-projects.vercel.app

Surrogate 440 pohon, 17 fitur: QWK 0,46752, atau 96,5% dari pipeline penuh. +0,06931 di antaranya berasal dari aturan keputusan saja.

- **Skrining satu orang** 17 pertanyaan, gauge $E[y]$, dan pendorong utama
- **Nilai kohort** 800 baris contoh dinilai di peramban, hasil diekspor CSV
- **Ambang dapat digeser** seret t_3 , jumlah tertangkap dihitung ulang
- **Tombol (i) di tiap istilah** rumus dan definisi untuk tanya jawab

Alat penapisan tingkat populasi, bukan diagnosis individual.

QWK out-of-fold 0,48425. Satu sel memikul 35,8% seluruh penalti.

Matriks konfusi dan sumbangan penalti atas 95.609 baris latih, lalu metrik per kelas.

Konfusi · prediksi →					Penalti (%) · prediksi →				
	1	2	3	4		1	2	3	4
1	30.414	11.918	576	60	1	0	28,89	5,58	1,31
2	14.757	28.477	4.389	566	2	35,77	0	10,64	5,49
3	157	1.412	1.369	621	3	1,52	3,42	0	1,51
4	140	226	262	265	4	3,05	2,19	0,64	0

Baris: kelas aktual 1 sampai 4.

0,48425

QWK OOF

0,63305

akurasi OOF

64,7%

penalti dari kebingungan kelas 1 dan 2

4,36%

penalti dari galat berjarak tiga

"Sangat puas" dan "Puas" berdekatan secara substantif, sebagian subjektif pada tingkat responden. Galat terjauh, yang penaltinya 9 kali, sudah ditekan di bawah 5%.

10 · METRIK PER KELAS

Kelas langka tertangkap

Kelas	presisi	recall	F1
1	0,6689	0,7078	0,6878
2	0,6775	0,5909	0,6313
3	0,2076	0,3847	0,2696
4	0,1753	0,2968	0,2204

Prediksi kelas 3 / aktual **6.596 / 3.559**


Prediksi kelas 4 / aktual **1.512 / 893**

Kelas 4 tertangkap benar **265 dari 893**

Menebak berlebih ke bawah skala disengaja: salah tebak 3 untuk orang kelas 2 berbiaya 1, gagal menangkap kelas 4 berbiaya 9. Kalibrasi diperiksa lewat diagram reliabilitas dan sudah dekat diagonal, jadi Platt maupun isotonik tidak dipakai.

Tak ada subkelompok tertinggal; 0,484 berarti kesepakatan sedang.

Galat per subkelompok, fitur paling berpengaruh, dan dua penggaris untuk membaca skor.




Plafonnya milik data, dan enam peringkat teratas tak terbedakan.

Kurva belajar pada lima ukuran data, ekstrapolasinya, dan bootstrap 400 kali atas matriks konfusi kami sendiri.

11 · KURVA BELAJAR

Dilatir ulang pada 12 sampai 100% data



$$QWK = 0,29209 + 0,01613 \cdot \ln(n)$$

R² terhadap lima titik

0,9143

Kenaikan per penggandaan data

+0,01118

11.1 · EKSTRAPOLASI

Data yang dibutuhkan per target

Target	Baris	Kelipatan
0,49	213.000	2×
0,50	396.000	4×
0,55	8.790.000	92×
0,60	195.000.000	2.041×

± 1.950 tahun

survei untuk QWK 0,60, dengan populasi dewasa sekitar 10⁵ baris per tahun

Kurvanya masih melambat, jadi angka ini terlalu optimistis. Klaim ini dapat difalsifikasi: jalankan ulang kurva yang sama, koefisiennya akan keluar sama.

DERAU PAPAN SKOR

Bootstrap 400 kali

0,0050

sd QWK, irisan seukuran data uji (23.666)

0,0105

sd QWK, irisan papan skor publik (7.100)

0,4625 – 0,5027

interval 95% skor kami di irisan itu

0,7 σ

selisih peringkat 4 sampai 9 (0,0075) dalam satuan sd

Selisih di bawah sekitar 0,02 lebih ditentukan irisan data daripada metodologi.

Satu eksekusi menghasilkan model, submission, dan semua angka ini.

Yang dikunci, yang diuji, yang dipenuhi terhadap aturan panitia, dan yang kami akui sebagai batas.

12 · REPRODUKSIBILITAS

Dikunci, disimpan, diuji

SEED / seed fold	42 / 0–4
PYTHONHASHSEED	diatur
Python · LightGBM	3.11.9 · 4.7.0
XGBoost · CatBoost	3.2.0 · 1.2.10
model_warkab.joblib	84,0 MB
Muat ulang	lulus
Waktu eksekusi	135,1 menit

7 uji integritas lulus: 23.666 baris, id unik, tanpa kosong, label {1,2,3,4}, id integer, semua id uji ada, model tersimpan.

Seed meta	QWK OOF	0,00029 rentang antar seed, sd 0,00015
7	0,48384	
202	0,48413	
999	0,48390	

14 · KEPATUHAN ATURAN

Setiap pasal dan letak pemenuhannya

Pasal	Pemenuhan
B.1.a	Hanya train dan test resmi
B.1.b	LightGBM, XGBoost, CatBoost, sklearn
B.1.c	Ambang dan model dari OOF latih
B.1.d	Dikerjakan internal tim
B.1.e	Tiap keputusan + bukti empiris
C	Alur end-to-end, bagian 1–12
C	SEED 42, FOLD_SEEDS, HASHSEED
C	Model tersimpan + uji muat ulang
C	Seluruh output sel terlihat
D	Submission dari notebook yang sama

BISA DIPERIKSA JURI

Artefak yang tersedia sekarang

Notebook teraksekusi penuh. seluruh output sel terlihat, 135,1 menit

model_warkab.joblib. 84 MB: model, meta, ambang, urutan fitur

submission.csv. 23.666 baris, lulus 7 uji integritas

Repository GitHub. github.com/MikaelAdikara/DataQuest-Warkab

Demo LifeScope. berjalan di peramban, tanpa server

Catatan eksperimen. 21 pendekatan ditolak, lengkap dengan angka

Apa yang belum bisa dilakukan model ini, dan bagaimana memperbaikinya.

Setiap keterbatasan dipasangkan dengan langkah perbaikan yang konkret.

Keterbatasan	Dampaknya	Pengembangan lanjut
Faktor psikososial tidak terekam	Plafon QWK sekitar 0,48 dari data yang ada	Tambah 3 sampai 5 butir kepribadian dan dukungan sosial ke instrumen
Kelas 4 hanya 893 sampel	Ambang t_3 paling goyah, sd bootstrap 0,0392	Kumpulkan label lintas gelombang survei; ambang peka biaya
Dilatih pada satu populasi survei	Belum tervalidasi untuk populasi Indonesia	Validasi eksternal pada survei kesehatan nasional sebelum dipakai
Kelas 1 dan 2 sebagian subjektif	64,7% penalti dari kebingungan dua kelas ini	Fokuskan pemakaian pada deteksi kelas 3 dan 4, bukan membedakan 1 dan 2
Distribusi bisa bergeser	Kalibrasi ambang menurun seiring waktu	Pantau drift dan kalibrasi ulang ambang tiap gelombang
Belum ada penjelasan per individu	Petugas sulit menjelaskan alasan prioritas	Penjelasan per orang (SHAP) dan audit keadilan per subkelompok
Determinisme boosting multi-thread	Selisih sekitar 0,001 QWK antar eksekusi	Mode single-thread untuk audit resmi

Kesimpulan, rekomendasi, dan jalan menuju implementasi nyata.

Dari skor lomba ke alat yang menolong orang: apa yang sudah terbukti, apa yang kami sarankan, dan bagaimana menjalankannya.

KESIMPULAN

0,48425

QWK out-of-fold: kesepakatan sedang, dekat plafon informasi data

89,9%

perbaikan datang dari aturan keputusan ordinal, bukan dari model yang lebih besar

0,00029

rentang antar seed: hasil stabil, bisa diulang, dan sudah menjadi produk

IMPLEMENTASI NYATA

- 1 Survei rutin berjalan
- 2 Skor $E[y]$ tiap responden
- 3 Daftar prioritas per wilayah
- 4 Tindak lanjut: konseling, rujukan
- 5 Label hasil kunjungan kembali
- 6 Kalibrasi ulang ambang

Siklus tertutup: setiap kunjungan menghasilkan label baru, sehingga model membaik tanpa survei tambahan.

Syarat etis: penapisan populasi, bukan diagnosis; persetujuan responden, data anonim, keputusan akhir oleh tenaga kesehatan.

REKOMENDASI

1. Pakai untuk populasi

Penapisan dan prioritas kelompok, bukan vonis individu.

2. Mulai dari data yang ada

Penapisan retrospektif pada gelombang survei lama bisa dilakukan hari ini.

3. Atur t_3 sesuai kapasitas

Ambang rendah menangkap lebih banyak orang; sesuaikan dengan jumlah konselor.

4. Tambah variabel, bukan model

Kurva belajar menunjukkan pengembalian algoritma sudah habis.

PENUTUP

**Di balik 4,7% itu ada 4.452 orang.
Kami membangun cara
menemukan mereka lebih awal.**

Dengan metodologi yang bisa diulang, keunggulan yang terukur, dan alat yang sudah bisa dicoba hari ini.

Tim Warkab

lifescope-mikaeladikara-5555s-projects.vercel.app

github.com/MikaelAdikara/DataQuest-Warkab

TIGA ANGKA UNTUK DIINGAT

+0,06269

dari aturan keputusan, tuas terbesar

0,9143

R² kurva belajar yang membuktikan plafonnya

0,7 σ

jarak enam peringkat papan skor

Terima kasih, kami siap menjawab pertanyaan.

Lampiran - 21 pendekatan yang diuji lalu ditolak.

Hasil negatif dilaporkan selengkap hasil positif, karena menjelaskan kenapa arsitektur akhirnya sesederhana ini.

Ditolak di notebook	Alasan	Bagian
Fitur komposit domain	Tidak ada perbaikan di ablasi	5.1
Kode 7/8/9 → NaN	Tidak membantu, kode bersinyal	3.3, 5.1
Target encoding rumah tangga	Lift +1,6pp, skor turun	3.5
id sebagai fitur	Spearman 0,006	3.6
argmax probabilitas	QWK jauh di bawah ambang	9
MLP sebagai model utama	Di bawah semua pohon	7.1
Ambang titik tunggal	Selisih split-half terbesar	9.1
Kalibrasi Platt / isotonik	Reliabilitas sudah diagonal	9.2
Indikator tahun survei	Target stabil antar tahun	3.8
Seleksi fitur agresif	Sinyal tersebar tipis	3.7

Di luar notebook (A.2)	Cakupan	QWK	Hasil
Hyperparameter acak	28 konfigurasi	0,465–0,467	Tak menonjol
Rekonstruksi nilai hilang	3.030.768 sel	0,4755–0,4806	Datar
Pembobotan sampel	4 tingkat	0,458–0,469	Turun monoton
Self-training	Pseudo-label uji	0,4735	Tak menembus
Pembobotan survei	survey_weight	0,4726	Tak menembus
Bagging 9 model	6 LGB + 3 Cat	0,4820	Di bawah stacking
Blending 25 kandidat	Greedy, z, rank	0,4834–0,4839	Setara terbaik
Vektor nilai kelas	Ganti (1,2,3,4)	0,4835	Tetap (1,2,3,4)
Aturan linear simpleks	argmax(W·p+b)	0,4744	Di bawah ordinal
TabPFN v2 GPU	Model fondasi	tak selesai	85 menit/bag
Ambang per segmen	Tahun, kesehatan, usia	tampak naik	Overfit

Rekonstruksi nilai hilang: 78 kolom pulih di atas 95%, lima sempurna, tetapi QWK datar di tingkat pemulihan 56, 79, dan 100%. Yang dipulihkan adalah redundansi, bukan sinyal.

Daftar pustaka.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of KDD 2016.

Cohen, J. (1968). Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. Psychological Bulletin, 70(4).

Diener, E., & Chan, M. Y. (2011). Happy people live longer: Subjective well-being contributes to health and longevity. Applied Psychology: Health and Well-Being, 3(1).

Efron, B. (1979). Bootstrap methods: Another look at the jackknife. The Annals of Statistics, 7(1).

Frank, E., & Hall, M. (2001). A simple approach to ordinal classification. ECML 2001, LNCS 2167.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5).

Huber, P. J. (1964). Robust estimation of a location parameter. The Annals of Mathematical Statistics, 35(1).

Kahneman, D., & Deaton, A. (2010). High income improves evaluation of life but not emotional well-being. PNAS, 107(38).

Ke, G., dkk. (2017). LightGBM: A highly efficient gradient boosting decision tree. NeurIPS 2017.

Kementerian Kesehatan RI. (2018). Laporan Nasional Riset Kesehatan Dasar (Riskesdas) 2018.

Koivumaa-Honkanen, H., dkk. (2001). Life satisfaction and suicide: A 20-year follow-up study. American Journal of Psychiatry, 158(3).

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. Biometrics, 33(1).

Lykken, D., & Tellegen, A. (1996). Happiness is a stochastic phenomenon. Psychological Science, 7(3).

OECD. (2013). OECD Guidelines on Measuring Subjective Well-being. OECD Publishing, Paris.

Prokhorenkova, L., dkk. (2018). CatBoost: Unbiased boosting with categorical features. NeurIPS 2018.

Wolpert, D. H. (1992). Stacked generalization. Neural Networks, 5(2).

World Health Organization. (2021). Suicide worldwide in 2019: Global health estimates.

World Health Organization. (2023). Depressive disorder (depression), fact sheet.