

Membaca Skala, Bukan Menebak Kelas

Memprediksi tingkat kepuasan hidup dari 176 variabel survei kesehatan, dengan seluruh pipeline dirancang untuk satu metrik: Quadratic Weighted Kappa.

DISTRIBUSI TARGET · 95.609 BARIS LATIH



Dua kelas terbawah hanya 4,7% dari data, dan di sanalah hampir seluruh penalti QWK berada.

0,48425

QWK out-of-fold

0,63305

Akurasi out-of-fold

6

Keluarga algoritma

176

Fitur mentah

42

Seed tunggal, dikunci

0

Baris data eksternal

Menandai siapa, bukan melaporkan berapa persen

Survei kesehatan sudah mengukur kepuasan hidup. Yang belum tersedia adalah cara memakainya untuk menandai individu yang perlu ditindaklanjuti.

Situasi

95.609 responden, 176 variabel per orang, empat tahun survei.
Kepuasan hidup dilaporkan sebagai satu persentase agregat dan berhenti di situ.

Kesenjangan

4.452 responden berada di dua kelas terbawah. Tanpa model, satu-satunya cara menemukan mereka adalah membaca ulang seluruh kuesioner, satu per satu.

MENGAPA INI BUKAN SOAL KLASIFIKASI BIASA

● $|p| = 0,361$

Prediktor tunggal terkuat. Sinyalnya tersebar tipis di banyak variabel, tidak terkonsentrasi di segelintir kolom.

● 893 baris

Seluruh data latih kelas 4. Kelas yang paling penting ditemukan justru yang paling langka.

● 9×

Penalti menebak kelas 4 sebagai kelas 1 dibandingkan menebak 2 sebagai 1. Kesalahan tidak setara.

Ukuran keberhasilan yang kami pakai: QWK di kompetisi, dan di lapangan, daftar prioritas yang terurut, bukan empat label. Kedua-duanya menuntut keluaran pada skala, bukan kelas.

Tiga temuan yang membentuk seluruh strategi

Setiap keputusan arsitektur dalam presentasi ini dapat dilacak kembali ke salah satu dari tiga temuan berikut.

1

Metrik ini menghukum kehati-hatian.

Menebak kelas mayoritas untuk semua orang memberi akurasi 50,402% dengan QWK persis 0,00000. Akurasi dan QWK di sini menarik ke arah berlawanan, jadi akurasi kami tolak sebagai panduan optimasi sejak awal.

2

Tuas terbesar bukan model, melainkan aturan keputusan.

Mengganti argmax dengan nilai harapan + tiga ambang batas pada model yang sama persis menaikkan QWK sebesar +0,06269. Seluruh sisa pekerjaan, lima model tambahan, stacking, dan studi ambang, hanya menyumbang +0,00708.

3

Kinerja mentok pada batas informasi, bukan batas teknik.

Enam keluarga algoritma yang bias induktifnya sangat berbeda semuanya mendarat di rentang 0,478–0,481. Kurva belajar ($R^2 = 0,9143$) memperlihatkan dindingnya milik data, bukan milik metode.

Hasil akhir: stacking enam model dasar → nilai harapan ordinal → tiga ambang batas yang diestimasi dengan rata-rata bootstrap. **QWK OOF 0,48425.**

Metrik ini menghukum kehati-hatian

QWK adalah galat kuadratik yang dinormalkan. Yang dihitung adalah jaraknya, bukan benar-salahnya.

		prediksi			
		1	2	3	4
aktual	1	0	1	4	9
	2	1	0	1	4
	3	4	1	0	1
	4	9	4	1	0

Bobot penalti $(i - j)^2$. Menebak kelas 4 sebagai kelas 1 dihukum 9× lebih berat daripada menebak 2 sebagai 1.

50,402%

Akurasi baseline kelas mayoritas

0,00000

QWK baseline kelas mayoritas

Strategi yang aman secara akurasi bernilai nol secara QWK. Metrik ini tidak memberi imbalan apa pun pada tebakan aman.

Dua konsekuensi desain yang kami ambil dari sini:

- Target diperlakukan sebagai skala ordinal, bukan empat kelas terpisah, karena penaltinya adalah fungsi jarak.
- Model harus berani menebak kelas 3 dan 4 meski keduanya hanya 4,7% data, menghindarinya justru merugikan.

Apa yang data katakan sebelum satu model pun dilatih

Empat pemeriksaan yang masing-masing langsung mengubah satu keputusan desain.

Target sangat timpang

Proporsi 44,9 / 50,4 / 3,7 / 0,9 persen. Kelas 4 hanya memiliki 893 baris latih.

→ Ambang batas ketiga akan menjadi parameter paling tidak stabil di seluruh pipeline. Kami mengukur ketidakstabilan itu, bukan mengabaikannya.

Missing bersifat struktural

14,4% sel kosong; 0 dari 176 kolom bebas missing. Korelasi pola missing train–test 0,9998.

→ Tanpa imputasi. Kekosongan adalah jejak alur kuesioner, dan ketiga pustaka boosting menanganinya sebagai cabang tersendiri.

Sinyal tersebar tipis

Prediktor tunggal terkuat hanya $|p| = 0,361$. Median $|p|$ antar 176 fitur hanya 0,037.

→ Seleksi fitur agresif merugikan: tidak ada kolom yang bisa dibuang tanpa kehilangan sedikit sinyal. Seluruh 176 fitur dipertahankan.

Tidak ada kebocoran urutan

$\text{Spearman}(\text{id}, \text{target}) = 0,00595$. Rentang mean target antar 20 bin id: 1,5925 – 1,6251.

→ Kolom id murni pengenalan. Kami memeriksanya lebih dulu justru agar tidak diam-diam memanfaatkan artefak penyusunan berkas.

Jebakan yang kami ukur, lalu tolak

Responden dalam dataset ini berbagi rumah tangga. 61,3% baris test punya anggota rumah tangga yang labelnya ada di data latih.

Target encoding di sini akan terlihat brilian pada validasi mana pun. Pertanyaannya bukan “bisakah dipakai”, melainkan “seberapa besar sebenarnya sinyalnya”.

P(label responden label anggota lain)	y _i = 1	y _i = 2	y _i = 3	y _i = 4
anggota lain menjawab 1 · Sangat puas	0,4654	0,4903	0,0354	0,0089
anggota lain menjawab 2 · Puas	0,4347	0,5200	0,0360	0,0093
anggota lain menjawab 3 · Tidak puas	0,4280	0,4902	0,0712	0,0106
anggota lain menjawab 4 · Sangat tidak puas	0,4294	0,5068	0,0425	0,0212

Keputusan: fitur ini kami buang, dan kami membuangnya berdasarkan besaran sinyalnya, bukan berdasarkan skor. Kepuasan hidup ternyata jauh lebih individual daripada dugaan awal: mengetahui jawaban orang yang serumah hampir tidak memberi tahu apa pun tentang jawaban responden sendiri.

LIFT SEBENARNYA

44,9% → 46,5%

+1,6 poin persentase

Dari marginal kelas 1 menuju kondisional terhadap anggota rumah tangga yang paling informatif.

11.620

Rumah tangga beririsan train–test

61,3%


Baris test yang terjangkau

Kami memprediksi posisi pada skala, bukan kelas

argmax adalah penduga optimal untuk akurasi. Untuk galat kuadratik pada skala ordinal, penduga optimalnya adalah nilai harapan.



ATURAN KEPUTUSAN




$E[y]$, nilai harapan pada skala kepuasan. Ketiga ambang diestimasi sepenuhnya dari out-of-fold data latih.

Konsekuensi yang terukur: argmax hanya pernah menebak kelas 3 atau 4 pada 0,70% baris, padahal proporsi sebenarnya 4,71%. Aturan ambang batas menaikannya ke 8,48%, sengaja melampaui proporsi aktual, karena di bawah penalti kuadratik biaya diam lebih mahal daripada biaya salah satu tingkat.

89,9% perbaikan datang dari aturan keputusan

Bukan dari model. Enam baseline dijalankan penuh, bukan diestimasi, sehingga sumbangan tiap komponen bisa dipisahkan satu per satu.



QWK out-of-fold, skala 0 – 0,5

+0,06269 baris 4 → 5


Hanya mengganti argmax dengan nilai harapan + ambang batas. Model, fitur, dan seed identik.

+0,00708 baris 5 → 6

Lima model dasar tambahan, stacking meta-learner, dan seluruh studi estimasi ambang batas, digabung.

Enam keluarga algoritma, satu dinding yang sama

Setiap keluarga dipilih karena bias induktifnya berbeda, bukan karena variasi hyperparameter dari model yang sama.



Sumbu dipotong pada 0,42 agar rentang antar model terlihat. Rentang sesungguhnya antar lima model pohon hanya 0,0033 QWK.

0,0033

Rentang QWK antar lima model pohon

0,974

Korelasi rata-rata prediksi antar model pohon

+0,00455

Sumbangan meta-learner di atas model dasar terbaik

Ketika enam kelas fungsi yang bias induktifnya sangat berbeda mendarat di titik yang sama, dindingnya berasal dari data, bukan dari model.

Kami tidak memilih strategi ambang batas dengan skor tertinggi

Lima strategi estimasi dijalankan penuh, lalu diuji ulang dengan split-half: pasang ambang pada separuh data, ukur pada separuh lainnya.

Strategi estimasi ambang batas	QWK OOF	in-sample	held-out	selisih
a. titik tunggal (optimum tunggal)	0,48517	0,48688	0,48083	0,00606
b. rata-rata bootstrap ← DIPILIH	0,48425	0,48625	0,48106	0,00519
c. rata-rata subsample	0,48419	0,48654	0,48100	0,00554
d. pencocokan distribusi	0,47413	0,47650	0,47206	0,00444
e. objektif dihaluskan	0,48435	—	—	—

Perhatikan baris a

Strategi dengan QWK OOF tertinggi justru punya selisih in-sample → held-out terbesar. Skornya tinggi karena ia dipasang dan diukur pada himpunan yang sama.

Kami memilih b: QWK OOF lebih rendah, held-out tertinggi, selisih terkecil.

Mengapa rata-rata bootstrap, dan mengapa ditetapkan di muka

Optimum tunggal menempatkan ambang tepat di satu puncak permukaan QWK, dan puncak itu sebagian dibentuk oleh derau sampling. Merata-ratakan ambang atas puluhan resampel bootstrap menempatkannya di **pusat dataran tinggi**, bukan di puncak derau. Ini argumen tentang variansi penduga, yang bisa diperiksa tanpa menyentuh data uji sama sekali, karena itu kami menetapkannya sebelum melihat perbandingan skor mana pun.

t_3 adalah titik paling rapuh di seluruh pipeline

Sebaran ambang batas atas resample bootstrap, bukan satu angka, melainkan distribusinya.



Simpangan baku estimasi ambang antar resample bootstrap

Mengapa ini penting untuk juri: ketidakstabilan t_3 adalah konsekuensi langsung dari langkanya kelas 4, dan tidak ada model yang bisa memperbaikinya. Kami tidak menyembunyikannya di keterbatasan, kami mengukurnya, lalu memilih strategi estimasi yang secara eksplisit mengurangi variansi itu. Untuk pemakaian nyata, rekomendasi kami adalah **menurunkan t_3 di bawah nilai optimum QWK**, karena penapisan kesehatan lebih menoleransi positif palsu daripada melewatkan kasus.

Hasil nol yang paling informatif dalam proyek ini

Dataset ini punya 14,4% sel kosong. Pertanyaan yang wajar: berapa banyak sinyal yang hilang bersamanya?

Kami melatih satu model rekonstruksi per kolom, memakai kolom-kolom lain di dalam dataset resmi, lalu memulihkan nilai yang hilang secara bertahap.

3.030.768

sel ter-mask dipulihkan seluruhnya

78

kolom direkonstruksi dengan akurasi di atas 95%,
lima di antaranya sempurna

0,4755 – 0,4806

QWK pada tiga tingkat pemulihan: 56%, 79%, dan
100%

Yang dapat dipulihkan adalah redundansi, bukan sinyal.

Memulihkan tiga juta sel tidak menaikkan QWK sama sekali, ketiga tingkat pemulihan menghasilkan skor yang praktis identik. Penjelasan lugas: nilai yang dapat ditebak dengan akurasi 99% dari kolom lain, menurut definisi, tidak membawa informasi baru. **Konsekuensinya untuk desain: kami berhenti mengejar imputasi dan mengarahkan seluruh sisa waktu ke kalibrasi aturan keputusan.**

Kami menangkap overfitting kami sendiri

Ambang batas per segmen adalah ide yang terdengar benar: kalibrasi berbeda untuk tahun survei, status kesehatan, dan kelompok usia yang berbeda.

Yang terlihat

QWK naik

Memasang ambang terpisah untuk setiap segmen, tahun survei, status kesehatan, kelompok usia, dan silangannya, konsisten menaikkan QWK pada himpunan tempat ambang itu dipasang. Semakin banyak segmen, semakin tinggi skornya.

Yang sebenarnya terjadi

held-out turun monoton

Uji split-half membongkarnya: setiap parameter tambahan menaikkan skor in-sample dan menurunkan skor held-out. Kenaikan itu bukan kalibrasi yang lebih baik, melainkan hafalan terhadap derau tiap segmen.

Keputusan: ditolak, dan kami membatasi diri pada tiga ambang global saja. Yang ingin kami tekankan bukan bahwa kami menemukan ide ini, melainkan bahwa kami **membangun alat untuk membunuhnya** sebelum mengirimkannya. Tanpa uji split-half, konfigurasi ini akan terlihat sebagai perbaikan terbesar kedua dalam proyek, dan akan merugikan kami di data uji. Pengalaman inilah yang mendasari seluruh kebijakan seleksi di slide berikutnya.

Enam belas pendekatan yang kami uji lalu tolak

Hasil negatif kami laporkan selengkap hasil positif. Daftar inilah yang menjelaskan mengapa arsitektur akhir sesederhana ini.

Eksperimen	Cakupan	QWK	Kesimpulan
Pencarian hyperparameter acak	28 konfigurasi LightGBM	0,465 – 0,467	Tidak ada yang menonjol
Rekonstruksi nilai hilang	3.030.768 sel dipulihkan penuh	0,4755 – 0,4806	Datar di tiga tingkat pemulihan
Pembobotan sampel	4 tingkat bobot kelas minoritas	0,458 – 0,469	Menurun monoton
Self-training	Pseudo-label data uji	0,4735	Tidak menembus
Pembobotan survei	survey_weight sebagai bobot latih	0,4726	Tidak menembus
Bagging 9 model	6 LightGBM + 3 CatBoost	0,4820	Di bawah stacking
Blending 25 kandidat	Greedy forward, z-score, rank-avg	0,4834 – 0,4839	Setara model tunggal terbaik
Vektor nilai kelas terlatih	Mengganti bobot (1,2,3,4)	0,4835	Optimum tetap (1,2,3,4)
Aturan linear pada simpleks	argmax($W \cdot p + b$), 20 parameter	0,4744	Di bawah pendekatan ordinal
Model fondasi tabular	TabPFN v2 pada GPU	tidak selesai	85 menit per bag
Ambang batas per segmen	Tahun, kesehatan, usia, silangannya	tampak naik	Terbukti overfit lewat split-half
Fitur komposit (ablasi)	Indeks gabungan buatan	–0,00090	Dibuang
Kode khusus 7/8/9 → NaN (ablasi)	Penanganan non-respons	+0,00111	Di bawah derau, dibuang
Target encoding rumah tangga	11.620 rumah tangga beririsan	lift +1,6pp	Ditolak sebelum dipakai

Dua ablasi tambahan, imputasi median dan seleksi fitur berbasis permutation, dijalankan di luar notebook dengan hasil serupa.

Tidak ada kriteria seleksi yang benar-benar bekerja

Kami mengevaluasi 25 konfigurasi, lima cara menggabungkan model dasar × lima strategi estimasi ambang, lalu menguji apakah kriteria seleksi kami sendiri mampu menunjuk pemenangnya.

Kriteria seleksi berbasis data latih	Korelasi dengan kinerja pada data uji
QWK out-of-fold	$\approx 0,08$
QWK held-out (uji split-half)	$\approx 0,16$

0,003

Rentang QWK di antara kedua puluh konfigurasi itu, lebih kecil daripada derau pengukurannya sendiri


Dihitung pada 20 konfigurasi yang sama-sama masuk akal, setelah satu strategi yang jelas buruk (pencocokan distribusi) dikeluarkan agar tidak menggelembungkan korelasi.

Mengejar skor validasi tertinggi pada rentang ini bukan optimasi. Itu memilih derau.

Karena itu kombinasi ensemble dan strategi ambang kami tetapkan di muka, berdasarkan alasan struktural yang bisa diperiksa tanpa data uji: rata-rata sederhana lebih tahan daripada meta-learner berparameter; anggota yang jelas lemah dikeluarkan lebih dulu; ambang batas diestimasi dengan reduksi variansi. **Ketiganya adalah argumen tentang sifat penduga, bukan tentang skor, dan karena itu tidak bisa overfit.**

Plafon ini milik data, bukan milik kami

Melatih ulang seluruh pipeline pada 12%, 25%, 45%, 70%, dan 100% data latih, lima titik, masing-masing dengan validasi silang sendiri.



$$\text{QWK} = 0,29209 + 0,01613 \cdot \ln(n)$$

0,9143

R² kecocokan model logaritmik terhadap lima titik terukur

+0,01118

Kenaikan QWK per penggandaan jumlah data latih

Dan kurva ini masih melambat, sehingga angka di atas justru terlalu optimistis.

Berapa data yang dibutuhkan untuk skor yang lebih tinggi

Menyelesaikan persamaan kurva belajar untuk n pada beberapa target QWK. Semua angka turun langsung dari koefisien di slide sebelumnya.


Target QWK	Baris data latih dibutuhkan	Kelipatan data saat ini	Waktu pengumpulan setara
0,49	213.000	2×	± 2 tahun survei
0,50	396.000	4×	± 4 tahun survei
0,55	8.790.000	92×	± 88 tahun survei
0,60	195.000.000	2.041×	± 1.950 tahun survei

Kolom terakhir memakai laju wajar survei kesehatan nasional, sekitar 10^5 responden dewasa per tahun, sebanding dengan laju yang menghasilkan dataset ini.

Klaim kami, dan klaim ini dapat difalsifikasi: dari dataset resmi kompetisi ini saja, QWK yang jauh di atas 0,50 tidak dapat dicapai dengan pemodelan yang lebih baik. Kisaran yang wajar adalah **0,47 – 0,50**. Siapa pun dapat menguji klaim ini: jalankan kurva belajar yang sama, dan koefisiennya akan keluar sama.

Enam peringkat teratas tidak dapat dibedakan secara statistik

Bootstrap 400× atas matriks konfusi out-of-fold kami sendiri (95.609 baris), mengukur berapa banyak QWK bergerak hanya karena baris mana yang kebetulan masuk irisan penilaian.



0,0050

Simpangan baku QWK pada irisan seukuran data uji penuh (23.666 baris)

0,0105

Simpangan baku QWK pada irisan seukuran papan skor publik (7.100 baris)

0,7 σ

Besarnya selisih enam peringkat berturut-turut, diukur dalam simpangan baku itu

Yang kami periksa sebelum menyebut pekerjaan ini selesai

Dua hal terpisah: apakah modelnya benar, dan apakah siapa pun bisa mendapatkan hasil yang sama.

VALIDASI

● Dekomposisi penalti, bukan sekadar matriks konfusi.

Satu sel, aktual 2 diprediksi 1, menyumbang 35,8% dari seluruh penalti QWK. Di situlah ambiguitas “Sangat puas” versus “Puas” yang sebagian memang subjektif.

● QWK per subkelompok.

Jenis kelamin 0,4839 vs 0,4836; diperiksa juga per kelompok usia, wilayah, dan tahun survei. Tidak ada segmen yang ditinggalkan model.

● Permutation importance, bukan split-gain.

Split-gain melebih-lebihkan fitur berkardinalitas tinggi. Permutation menempatkan survey_weight, pseudo_stratum, dan pseudo_psu di delapan besar, variabel desain survei, bukan variabel substantif. Kami mengujinya sebagai bobot latih: QWK turun ke 0,4726, jadi keduanya tetap sekadar fitur.

REPRODUKSIBILITAS

● Satu seed, dikunci di setiap tahap.

SEED = 42 diteruskan ke pembagian fold, keenam model dasar, meta-learner, resample bootstrap, dan analisis kurva belajar.

● Model tersimpan lengkap, bukan hanya bobot.


model_warkab.joblib memuat keenam model dasar, meta-learner, ketiga ambang batas, dan daftar 176 fitur dalam urutan yang benar, cukup untuk memproduksi ulang submission tanpa melatih apa pun.

● Notebook dijalankan penuh dari awal.

Eksekusi penuh 135 menit, seluruh sel berisi output, nol error, dan berkas submission yang dihasilkan identik dengan yang kami kumpulkan. Batasan yang kami akui: pustaka boosting multi-thread tidak menjamin hasil bit-identik; selisihnya terukur sekitar 0,001 QWK.

Dari notebook ke alat yang bisa dipakai: LifeScope

Aturan keputusan yang sama, dibungkus menjadi alat penapisan yang berjalan sepenuhnya di peramban, tanpa server, tanpa data yang dikirim ke mana pun.



Halaman Ikhtisar: tujuan produk, tiga angka yang mendasarinya, dan empat titik masuk.

COBA LANGSUNG SAAT PITCHING

mikaeladikara.github.io/DataQuest-Warkab

github.com/MikaelAdikara/DataQuest-Warkab

Tujuannya terbaca dalam sekali lihat

Grid 200 kotak, tiap kotak satu responden, pada proporsi kelas sebenarnya. Sembilan kotak hangat di ujung adalah 4,7% yang jadi alasan alat ini dibuat.

Ambang penapisan dapat digeser

Garis t_3 diseret langsung di histogram: batangnya berubah warna seketika, dan jumlah orang yang tertangkap terhitung ulang di depan mata juri.

Tombol (i) di tiap istilah teknis

Rumus $E[y]$, bobot QWK, dan definisi out-of-fold muncul sebagai popover saat diklik. Siap dipakai menjawab pertanyaan teknis tanpa pindah slide.

Jalur dari prototipe ke pemakaian nyata

Setiap langkah disertai syarat yang harus dipenuhi lebih dulu. Kami menuliskan syaratnya karena melewatinya adalah cara model seperti ini biasanya gagal.

01

Penapisan retrospektif

Menjalankan model pada gelombang survei yang sudah ada untuk menemukan segmen berisiko rendah kepuasan hidup.

Syarat: tidak ada. Dapat dilakukan hari ini dengan data yang sudah dimiliki.

02

Prioritisasi tindak lanjut

Memakai peringkat $E[y]$, bukan label, untuk menyusun antrean kunjungan atau wawancara lanjutan.

Syarat: t_3 dikalibrasi ulang untuk sensitivitas, bukan untuk QWK. Slider pada prototipe adalah alatnya.

03

Instrumen singkat 17 pertanyaan

Model ringkas pada prototipe memakai variabel yang dapat ditanyakan dalam wawancara beberapa menit.

Syarat: validasi ulang pada populasi sasaran, model ini dilatih pada satu instrumen, satu negara, 2021–2024.

04

Menambah variabel, bukan model

Kepribadian, kualitas hubungan sosial, dan rasa bermakna hidup adalah variabel yang hilang.

Syarat: pengumpulan data baru. Analisis plafon menunjukkan tidak ada jalan pintas algoritmik ke sini.

Batas yang kami pegang: alat penapisan tingkat populasi, bukan keputusan individual. Untuk satu responden, sebaran $E[y]$ kelas 1 dan 2 bertumpang tindih terlalu lebar untuk dipakai sendiri.

Apa yang layak dilakukan dengan model ini, dan setelahnya

Model yang baik disertai petunjuk pemakaian yang jujur, termasuk batas di mana ia tidak boleh dipakai.

1 Untuk pemakaian model

Penapisan tingkat populasi, bukan keputusan individual.

QWK 0,48 memadai untuk mengidentifikasi kelompok berisiko dalam perencanaan program kesehatan. Untuk satu responden, sebaran $E[y]$ kelas 1 dan 2 bertumpang tindih sangat lebar.

Turunkan t_3 bila dipakai untuk penapisan.

Optimum QWK menyeimbangkan seluruh kelas; penapisan kesehatan lebih menoleransi positif palsu daripada melewatkan kasus.

2 Untuk pengembangan lanjutan

Tambah variabel, bukan tambah model.

Kurva belajar menunjukkan pengembalian dari perbaikan algoritma sudah habis. Yang hilang bersifat substantif: kepribadian, kualitas hubungan sosial, rasa bermakna hidup, riwayat peristiwa besar.

Satu instrumen kepribadian saja berpotensi melampaui seluruh notebook ini.

Perkiraan yang sengaja provokatif, dan konsisten dengan besaran sisa variasi yang tak teramati.

3 Untuk membaca skor kompetisi

Kisaran wajar dari dataset ini: 0,47 – 0,50.

Skor di dalamnya menandakan pipeline yang sudah mendekati batas informasi; selisih kecil di dalam kisaran itu lebih mencerminkan derau sampling daripada kualitas metodologi.

Enam belas pendekatan yang kami tolak kami dokumentasikan lengkap dengan angkanya.

Tujuannya agar tim berikutnya tidak mengulang jalan buntu yang sama.

PENUTUP

**Kami tidak mengejar angka.
Kami memetakan batasnya,
lalu berhenti tepat di sana.**

Setiap keputusan dalam pipeline ini punya angka yang mendasarinya, dan setiap angka itu dapat dijalankan ulang dari notebook yang kami kumpulkan. Yang kami tolak didokumentasikan selengkap yang kami pakai.

Tim Warkab

Objective Quest DataQuest 5.0 · prediksi life_satisfaction · Quadratic Weighted Kappa

TIGA ANGKA UNTUK DIINGAT

+0,06269

dari aturan keputusan ordinal, tuas terbesar dalam kompetisi ini

0,9143

R² kurva belajar yang membuktikan plafon ini milik data

0,7 σ

jarak enam peringkat papan skor, diukur dalam derau sampling

Terima kasih, kami siap menjawab pertanyaan.